

《计算机器与智能》阅读报告

2451951 数据科学与大数据技术 于沛可

问题一：图灵这篇文章作为人工智能的开山之作，在哪些方面预言了未来？

我的回答：

首先，图灵提出的“儿童机器”通过惩罚奖励训练正对应了如今机器学习和深度学习算法中，通过损失函数来训练模型参数；

其次，图灵指出要通过模仿游戏，机器需要巨大的存储容量（他当时预测是10^9字节），这预言了大数据与算力是智能的门槛。

最后，图灵提出了“通用机器”的概念。他指出，只要给离散状态机足够的存储空间和速度，并配合适当的程序，它就能模拟任何其他机器。这体现了 AGI 的思想。以前我们认为翻译需要翻译机，下棋需要下棋机；但图灵预言了单一硬件+不同软件可以解决所有问题。例如，如今我们用同一个 Transformer 架构（软件）跑在同样的 H100 显卡（硬件）上，可以干许多事，验证了图灵的通用性预言。

AI 回答：

图灵在第 7 节详细描述了通过“奖励（Pleasure）”和“惩罚（Pain）”来训练机器。他提到，机器在收到惩罚信号时会降低该行为的发生概率。现代回响：这就是强化学习 （Reinforcement Learning）。惩罚信号 = Loss Function / Negative Reward.奖励信号 = Backpropagation / Positive Reward。现在的机器人控制、AlphaGo 乃至 ChatGPT 的 RLHF（人类反馈强化学习），其核心逻辑完全没有跳出图灵当年设想的“奖惩循环”。

同时他预言了“机器学习”取代“手工编程”。在最著名的第 7 节《学习机器》中，图灵提出了放弃“成人大脑”转向“儿童大脑”的观点。他认为与其雇佣成千上万的程序员去写死规则，不如让机器自己去学。这直接预言了从“专家系统”到“深度学习”的范式转移。专家系统（失败）：人类试图手动输入所有规则（如果看到猫耳朵，就是猫）。深度学习（成功）：我们给模型看一万张猫的照片，让它自己提取特征。图灵在 70 多年前就看透了：教育机器比编程机器更有效。

问题二：图灵在第七节末尾强调了在机器中引入“随机元素（Random Element）”，它的意义是什么？

我的回答：

此“随机元素”让我联想到在如今的机器学习中许多算法存在陷入局部最优解的问题，为了解决此问题在算法中引入随机性，例如，在训练阶段，使用随机梯度下降和 Dropout（随机丢弃神经元）来防止模型过拟合，帮它跳出局部最优；在推理生成阶段，比如 Transformer 大语言模型中引入了温度参数。这些都体现了图灵“随机元素”的思想。

AI 回答：

图灵认为，在一个旨在寻找某种特定答案（比如密码破译或下棋）的学习机器中，如果不加入随机性，机器很容易陷入某种死板的、可预测的循环中。加入“随机元素”后，机器的搜索空间会变得更广，它能够跳出固定的模式去尝试新的可能性。图灵甚至将这种随机机制与进化论中的“随机突变”相提并论，认为这是机器产生类似于人类“直觉”和“创造力”的关键。

问题三：为什么图灵要用“模仿游戏”来取代“机器能否思考”这个终极问题？

我的回答：

在计算机科学中，这本质上就是一种黑盒测试。我们不需要研究机器内部去争论机器到底有没有灵魂，我们只看它的输入和输出。只要它的输出结果在统计学和逻辑上与人类无异，我们就承认它的功能。如今评测大模型（如 GPT-4）的各种基准测试（Benchmarks）和盲测竞技场，正是图灵测试在当代的直接延续。

AI 回答：

图灵认为，“机器”和“思考”这两个词在日常语言中太过模糊，如果陷入哲学定义，争论将毫无结果。因此，他设计了“模仿游戏”（即后人熟知的图灵测试）。在这个游戏中，一个人类测试者通过电传打字机与另一个人类和一台机器进行交流。如果测试者无法分辨出哪个是机器，那么这台机器就通过了测试。图灵用这个可观测的、基于对话表现的测试，巧妙地避开了关于“意识”的无休止争论。

问题四：如何看待洛夫莱斯夫人的反对意见即机器永远无法产生原创性？

我的回答：

洛夫莱斯夫人的观点在确定性算法时代是正确的，但在生成式 AI 时代被打破了。如今的 Transformer 架构或 OmniPaint 等模型，并不是在机械地重复指令，而是在高维概率空间中进行采样。虽然 AI 的训练素材来自人类，但它通过对特征的重新组合产生了人类未曾预料到的结果。这让我意识到：“原创性”可能并不

灵感是专属人类的，而是一种极度复杂的特征重组。

AI 回答：

洛夫莱斯夫人认为，分析机（机器）没有任何创作意愿，它只能执行我们命令它执行的任务。图灵在文中反驳道，机器其实经常让他“感到惊讶”。他认为这种反对意见的核心在于：人们往往低估了复杂系统可能产生的涌现行为。当规则足够复杂、数据量足够大时，机器给出的反馈往往会超出设计者的预期，从而产生类似“原创”的效果。

问题五：图灵如何反驳哥德尔定理对机器的限制？

我的回答：

这一节对我的启发在于，它揭示了符号主义（逻辑）与连接主义（概率）的本质区别。哥德尔定理限制的是严密的逻辑推理系统，但现在的神经网络（如我之前提到的 GNN 或 CNN）本质上是启发式的。它们不追求在数学上绝对不可推翻的证明，而是追求在统计学上的极大似然。例如，AI 4 Science 中，我们并不需要 AI 证明每一个物理定理，而是需要它通过计算帮我们找到最优的晶体结构。图灵告诉我们，承认机器的不完美和易错性，才是让机器走向真正智能的开始。

AI 回答：

数学反对意见引用了哥德尔不完备定理等结论，认为在任何逻辑系统中都存在机器无法证明的真命题，因此机器不如人类。图灵的反驳非常辛辣：他指出人类同样是易错的。仅仅因为机器在某些极端数学逻辑上存在极限，并不能证明人类就优于机器，因为人类在进行逻辑推导时也经常犯错或陷入僵局。图灵建议，我们不应要求机器是“完美的”，而应看它是否在大多数情况下表现得足够好。