同济大学

TONGJI UNIVERSITY

《人工智能原理与技术》
期中大作业报告

课题名称 基于注意力机制与扩散模型的多事件视频生成系统

学　　院 计算机科学与技术学院

专　　业 数据科学与大数据技术

学生姓名 于沛可

学　　号 2451951

指导教师 王俊丽老师

日　　期 2026 年 4 月 24 日

基于注意力机制与扩散模型的多事件视频生成系统

摘 要

近年来，以扩散模型（Diffusion Model）为代表的生成式人工智能技术（AIGC）在图像、视频等内容创作领域取得了显著进展，尤其是ChatGPT旗下模型image-2的出世，使图像生成达到了以假乱真的效果。然而，对于视频生成，大多数方法依赖高昂的训练成本与海量数据，迁移至新场景往往会遇到困难。今年初，以 SwitchCraft（西湖大学 AGI Lab，2024）为代表的 Training-Free 范式为多事件视频编辑提供了一种全新的思路：在不重新训练模型的前提下，仅通过修改扩散过程中的注意力特征，就能实现按时序发展的多事件场景内容自然、和谐的切换。本文以课程中所涉及到的前馈神经网络、卷积神经网络、注意力机制等基础知识为出发点，结合 U-Net、Vision Transformer（ViT）、Prompt-to-Prompt、TokenFlow 等前沿成果，聚焦于多事件视频生成中的时序控制问题。在复现并深入分析 Wan-2.1 T2V 模型与 SwitchCraft 框架的基础上，通过几组对照实验，我对模型在多主体并发场景下失效的现象进行了机制分析。定量观察表明，在动态并发场景中，底层自适应强度求解器（ABSS）的抑制系数出现了显著的异常极值，导致注意力查询向量（Q 向量）发生严重偏移，并发语义随之丢失，最终退化为顺序生成。研究排除了时序连词、输入粒度等替代假说，初步表明现有的注意力时序分配策略在处理多主体空间竞争语义时存在底层架构的局限性。在此基础上，本文对未来引入空间先验和动态掩码的改进方向进行了探讨，并给出了一个交互产品的设计概念。

关键词：扩散模型；注意力机制；Training-Free 编辑；U-Net；ViT；多事件视频生成

目录

摘 要 2

1 引言 5

2 技术基础 5

2.1 注意力机制：从 Seq2Seq 到 Transformer 5

2.2 U-Net：扩散模型的骨干网络 6

2.3 扩散型 Transformer（Diffusion Transformer, DiT） 7

2.4 扩散模型基础 8

3 相关工作 9

3.1 骨干模型：Wan-2.1 9

3.2 SwitchCraft：Training-Free 多事件时序控制 9

4 基础复现与初步观察 10

4.1 单事件有效性验证 10

4.2 多主体场景的初步失败观察 13

5 失效机制的深层排查与系统性分析 13

5.1 提示词时序连词的影响 13

5.2 锚点词（Anchor Token）的语义粒度 13

5.3 底层求解器（ABSS）数据的定量提取（核心发现） 14

5.4 抑制系数的强制截断测试 14

5.5 取消时序分段的极端测试 14

5.6 叠加交叉注意力空间掩码 15

5.7 机制局限性结论 18

6 进一步的优化思路与展望 18
6.1 尝试引入外部的空间先验信息 18
6.2 让注意力干预的时序边界变得更平滑 19
7 交互产品设计概念 19
7.1 设计目标 19
7.2 界面设计概念 19
7.3 技术可行性分析 20
8 总结 22
参考文献 22

1 引言

这篇报告的选题其实源于我在课外研究视频生成模型时遇到的一个困惑：在跑通 WAN（通义万相视频生成框架）和 SwitchCraft 之后，我发现一件有意思的事：同样是描述一段先是晴天草地、然后切换到雨夜城市的视频，WAN 生成出来的结果在场景切换处会出现明显的跳变，帧与帧之间缺乏连续性；而 SwitchCraft 的 Training-Free 机制可以在不从头开始训练模型的前提下，让两段内容之间的过渡变得自然得多。这让我想到课堂上的知识去理解：这背后到底发生了什么？注意力机制为什么有这个能力？

带着这个问题，我参照了课程第五章的内容——从卷积神经网络到循环神经网络，再到注意力机制——并查阅了大量文献。逐渐地，我发现这不仅仅是一个如何生成好看视频的问题，更是一个关于如何在不重新训练模型的前提下，用结构化的方式控制生成过程的研究课题。于是我决定以此为题，把我的理解和一些自己的设想写成这篇报告。

本文的组织结构如下：第 2 章梳理注意力机制、DiT 架构和扩散模型的技术基础；第 3 章介绍 Wan-2.1 和 SwitchCraft 的核心机制及相关工作；第 4 章报告基础复现实验；第 5 章对 SwitchCraft 的失效机制进行分析；第 6 章提出改进方向；第 7 章给出交互产品的设计概念；第 8 章总结全文。

2 技术基础

2.1 注意力机制：从 Seq2Seq 到 Transformer

注意力机制的初衷，在于克服经典 Seq2Seq 模型处理长序列时的信息衰减痼疾。早期的编解码器习惯将全部输入强行压缩成一个固定长度的上下文向量。这种做法的弊端显而易见：一旦输入序列过长，先前的上下文就会被后续内容逐渐挤占甚至覆盖。为此，注意力机制摒弃了对单一静态向量的依赖，允许解码器在生成每个词时，动态地去查阅编码器端所有的隐藏状态。通过计算并分配不同的权重，模型能够自发地将焦点集中在对当前输出最有价值的位置上。这种基于全局权重的空间与时序信息捕获能力，正是后续 DiT 架构能够在视频生成中保持跨帧连贯性的核心基石。

2017 年，Vaswani 等人提出的 Transformer 架构将注意力机制推向了极致——完全抛弃了循环结构，只用注意力来建模序列关系。其核心是 Scaled Dot-Product Attention，计算方式为[1]：

$$Attention(Q,K,V)=softmax(\frac{QK^T}{\sqrt{d_k}})V$$

其中 Q（Query）、K（Key）、V（Value）分别是输入经线性变换后的三组矩阵。直觉上，Q 是“我在找什么”，K 是“我能提供什么信息的索引”，V 是“实际的信息内容”。计算 Q 与所有 K 的点积，经 softmax 归一化得到注意力权重，再对 V 加权求和，就得

到了当前位置的输出表示。除以 $\sqrt{d_k}$ 是为了防止点积值过大导致 softmax 梯度消失。

在视频生成的语境中，注意力机制被分成两类：Self-Attention（自注意力）和 Cross-Attention（交叉注意力）。前者让图像的每个 patch 与其他所有 patch 进行交互，捕捉画面内部的结构关系；后者则让图像特征与文本描述进行交互，将语义内容注入生成结果。这个区别在后面理解 Training-Free 编辑时非常关键——简单来说，Self-Attention 负责“长什么样”，Cross-Attention 负责“是什么内容”。

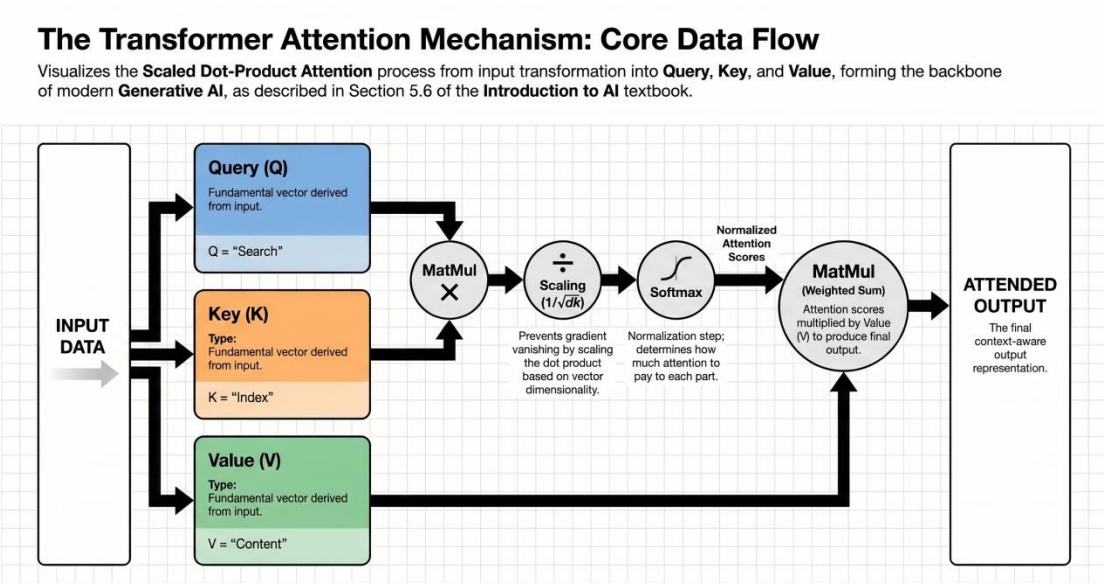


图 1：Transformer 原理示意图

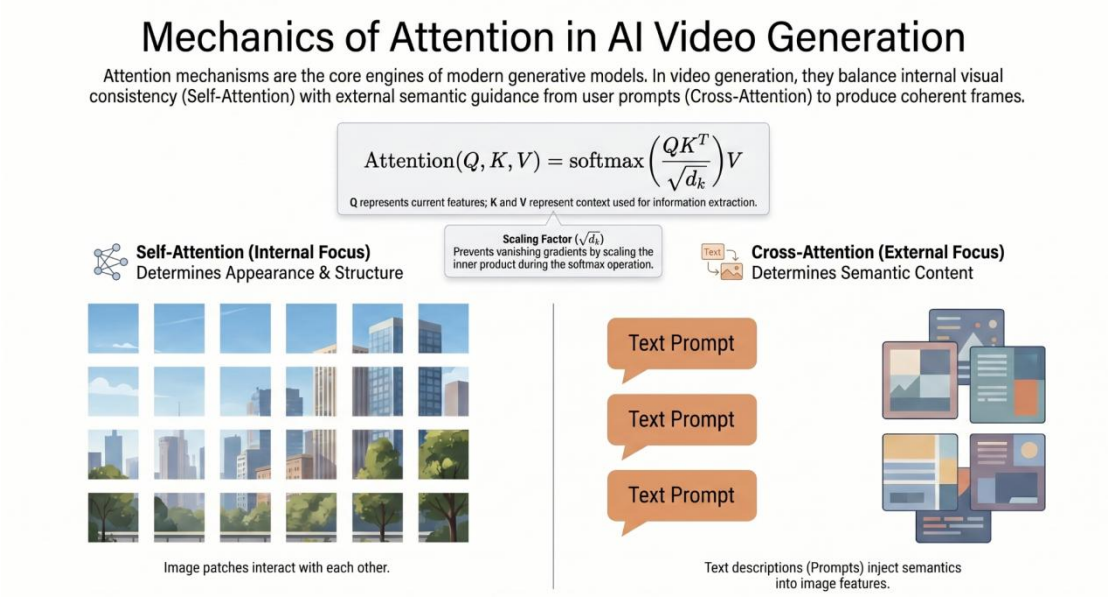


图 2：视频生成中的注意力机制原理示意图

2.2 U-Net：扩散模型的骨干网络

U-Net 最早由 Ronneberger 等人（2015）提出，用于医学图像分割。它的结构像一个 U 形：左边是编码器，通过卷积和下采样逐步提取特征、压缩空间分辨率；右边是解码器，通过上采样还原空间分辨率；两侧对应层之间有跳跃连接（Skip Connection），把编码器的细节特征直接拼接到解码器对应层，避免信息在压缩过程中丢失。

这个设计在扩散模型中被重新发现并大规模采用。在 Stable Diffusion 这类基于潜在扩散（Latent Diffusion）的框架里，U-Net 是负责预测噪声的核心网络。它被加入了 Transformer 模块：在 U-Net 的中间层（bottleneck）和解码器的每个 block 里，都嵌入了 Self-Attention 和 Cross-Attention 层。这样的设计让 U-Net 既保留了 CNN 在空间特征提取上的优势，又获得了 Transformer 的全局建模能力和文本条件控制能力[7]。

一个重要的观察是：U-Net 中间层的特征包含了丰富的语义信息，而浅层的特征更多对应纹理和低层细节。Training-Free 编辑方法的很多思路都建立在这个观察上——通过替换或混合不同时间步、不同内容条件下的中间层特征，可以实现对生成结果的精确控制，而不需要动模型本身的任何参数。

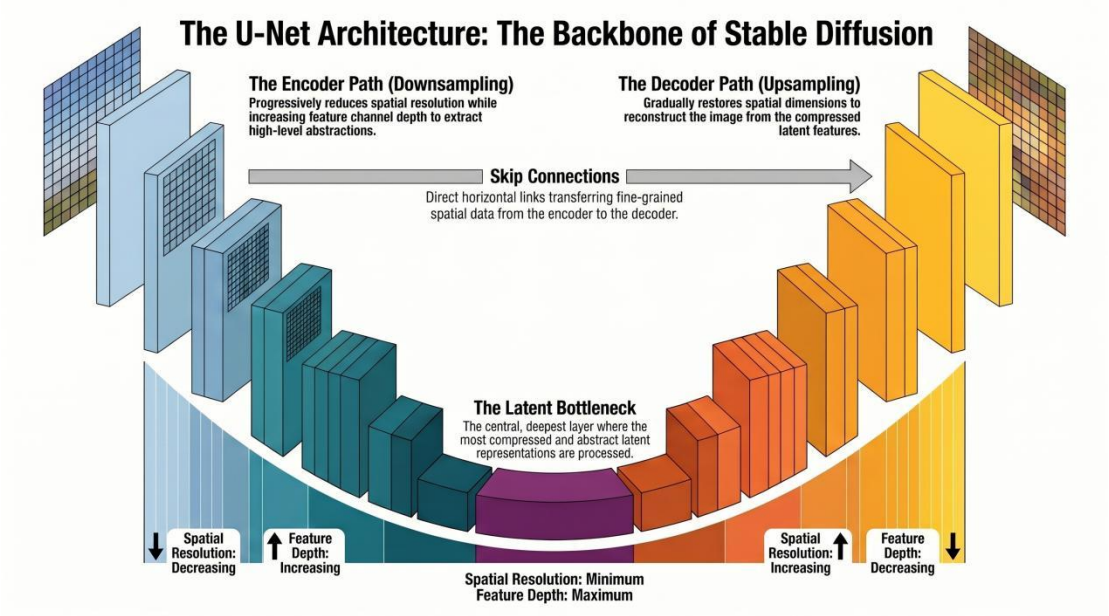


图 3：Unet 原理示意图

2.3 扩散型 Transformer（Diffusion Transformer，DiT）

DiT 由 Peebles 和 Xie（ICCV 2023）提出，代表了生成模型架构的一场范式转移——它正式摒弃了传统的 U-Net 卷积骨干，全面转向 Transformer 架构。如图所示，DiT 的核心思想是首先将潜在空间（Latent Space）的图像特征或视频帧切分为固定大小的图像块（Patchification），然后将这些块展平为一维的 token 序列。与传统卷积受限于局部感受野不同，DiT 将这些 token 序列直接送入由序列化 Transformer 块（Transformer Blocks）组成的深层网络中。在每个网络块内部，自注意力机制（Self-Attention）负责让所有空间和时间维度的 patch 互相进行全局特征交互，而交叉注意力机制（Cross-Attention）则负责将文

本特征（Text Prompt）精确注入到这些 patch 中[5][6]。

此外，DiT 巧妙地采用自适应层归一化（adaLN）机制，将扩散模型的去噪时间步 t 作为调节参数动态注入到每一层的尺度（scale）和偏移（shift）中。DiT 架构对本研究具有至关重要的影响。本文所研究的 Wan-2.1 模型正是基于 DiT 构建，并将其暴力扩展到了 40 个 Transformer 块和 40 个注意力头。

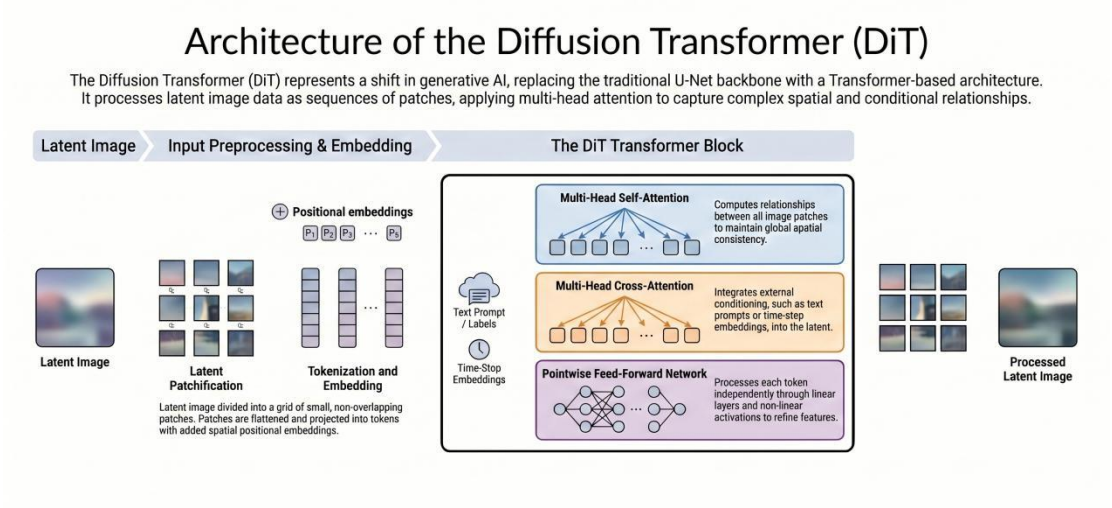


图 4：DiT 原理示意图

2.4 扩散模型基础

扩散模型（Denoising Diffusion Probabilistic Models，DDPM）由 Ho 等人（2020）正式提出。其基本思路分两个阶段：正向扩散过程（Forward Process）逐步向真实图像加高斯噪声，经过 T 步后图像变为纯噪声；反向去噪过程（Reverse Process）训练一个神经网络（通常是 U-Net），学习在每一步预测并去除噪声，从而将纯噪声还原为真实图像[2]。

Song 等人（2020）进一步提出了 DDIM（Denoising Diffusion Implicit Models），将采样过程从马尔可夫链改为确定性过程，大幅减少了推理时所需的步数，并且 DDIM 反转（DDIM Inversion）允许将真实图像反推回对应的噪声表示，这为 Training-Free 编辑提供了关键工具：先将原始视频帧反转为噪声，再在重建过程中注入新的文本条件，从而实现内容替换[3]。

Rombach 等人（2022）提出的 Latent Diffusion Model（LDM）将扩散过程从像素空间迁移到 VAE 编码的潜在空间，大幅降低了计算成本，这也是 Stable Diffusion 系列的核心创新[4]。视频生成领域的 WAN、VideoCrafter 等框架均建立在 LDM 之上，将 U-Net 替换为时空感知的 3D 结构。

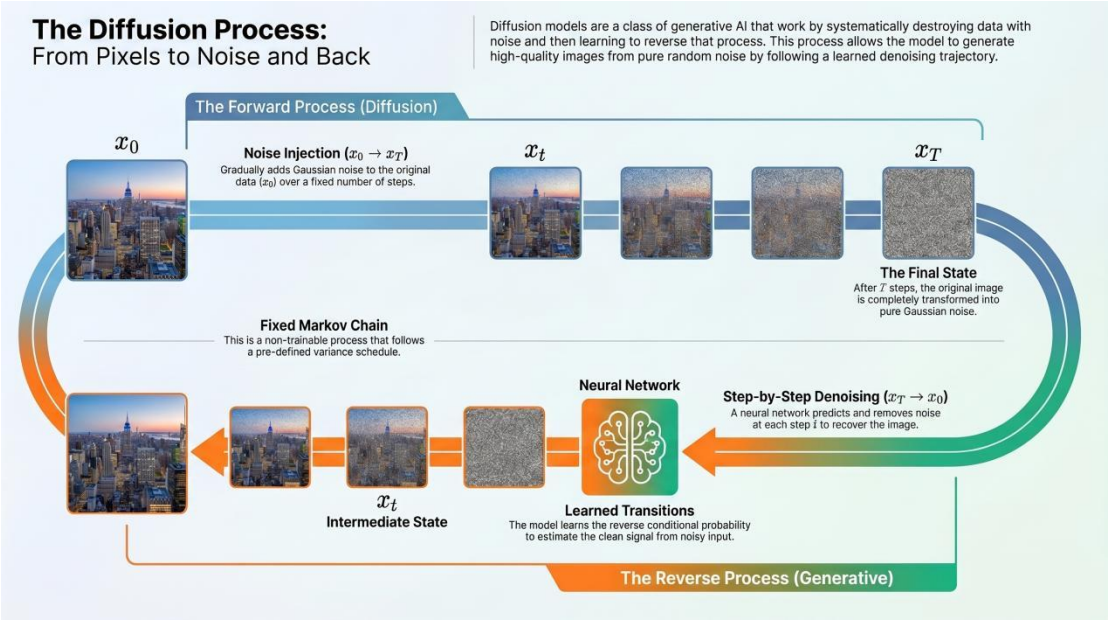


图 5：扩散模型原理示意图

3 相关工作

3.1 骨干模型：Wan-2.1

Wan-2.1（Wang 等，arXiv:2503.20314，2025）是目前最强的开源 T2V 模型之一，基于 DiT + Flow Matching 框架[8][9]。其架构核心包括：3D-VAE（将视频压缩到时空下采样的潜在空间）、T5-XXL 文本编码器（负责将提示词转化为语义向量）、以及具有 40 个 Transformer 块和 40 个注意力头的 DiT 主干。Wan-2.1 在空间和时间维度同时做 Full Attention（3D 全注意力），使跨帧内容一致性更强，但这也使得对特定时间段进行分段控制更加困难——这是后续所有干预方法面临的共同挑战。

3.2 SwitchCraft：Training-Free 多事件时序控制

SwitchCraft 针对 T2V 模型在多事件 prompt 下的时序混淆问题，提出了一套 Training-Free 的注意力干预框架。其核心洞察是：现有模型将完整提示词均匀注入所有帧，导致每一帧都受到所有事件语义的影响。SwitchCraft 通过两个模块解决这一问题：事件对齐查询导向（EAQS，Event-Aligned Query Steering）对每个时序窗口内的帧修改 Cross-Attention 的 Query 向量，公式为

$$Q^* \leftarrow Q^* + \alpha \cdot Q^* P_{tgt} - \beta \cdot Q^* P_{oth}$$

其中 P_tgt 和 P_oth 分别是目标事件和竞争事件的键向量投影矩阵；自适应强度求解器（ABSS，Auto-Balance Strength Solver）通过对 Q 与事件主方向的对齐差距（gap）求解凸优化问题，自动计算每步的增强系数 α 和抑制系数 β。该方法在 Wan-2.1 T2V 14B 上实现，干预仅作用于前 20 步和前 20 个 DiT 块[10]。

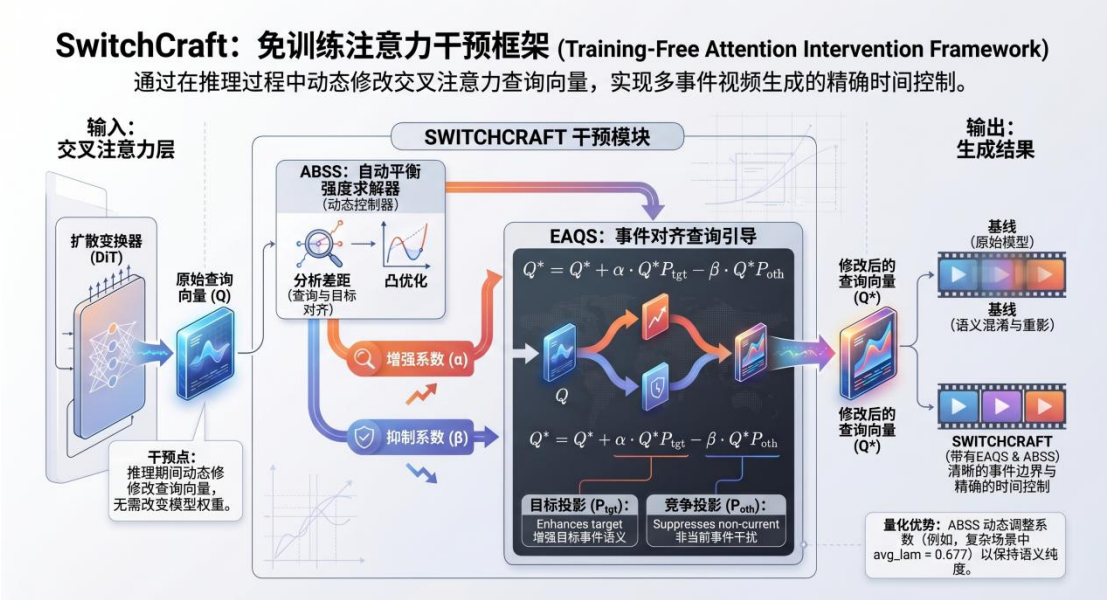


图 6：SwitchCraft 原理示意图

3.3 其他相关工作

在 Training-Free 图像编辑领域，Hertz 等人提出的 Prompt-to-Prompt[12]最早系统地揭示了扩散模型 Cross-Attention Map 与图像语义区域之间的对应关系，为后续所有基于注意力干预的方法奠定了理论基础；Geyer 等人提出的 TokenFlow [16]则将这一思路延伸至视频，通过跨帧共享 Self-Attention 特征实现了时序一致的视频编辑，是本文所关注的视频生成控制方向的重要前驱工作。在多事件视频生成领域，MEVG[13]采用逐段拼接的策略生成多事件视频，但各段之间缺乏全局上下文共享；Mind the Time（MinT）[14]则通过在训练阶段引入时间感知的 Cross-Attention 监督实现了精准的时序绑定，但需要昂贵的微调成本；DiTCtrl [15]基于预训练 DiT 模型对注意力进行时序编辑，与 SwitchCraft 同属 Training-Free 路线，但其方案在场景一致性上仍有不足。上述工作共同构成了本研究的方法背景。

4 基础复现与初步观察

4.1 单事件有效性验证

在服务器环境下，我比较了 Wan-2.1（1.3B）与 SwitchCraft 在单事件切换场景下的表现。测试提示词为“A white cat is walking on the grass. Suddenly, the scene shows a red sports car accelerating on a racing track.”，action words 为 cat, car，event_len_ratio 为 1,1，共生成 65 帧。结果显示，Wan-2.1 在过渡阶段出现明显的语义提前泄漏与同帧混叠（可见猫与车的叠加残影）；SwitchCraft 显著减少了同帧共现，呈现出更可分的先猫后车时序。需要指出的是，SwitchCraft 在切换附近存在短暂低信息过渡帧，且切换时刻并非严格位于理论中点，但整体事件解耦效果是要优于 Wan 基线的。

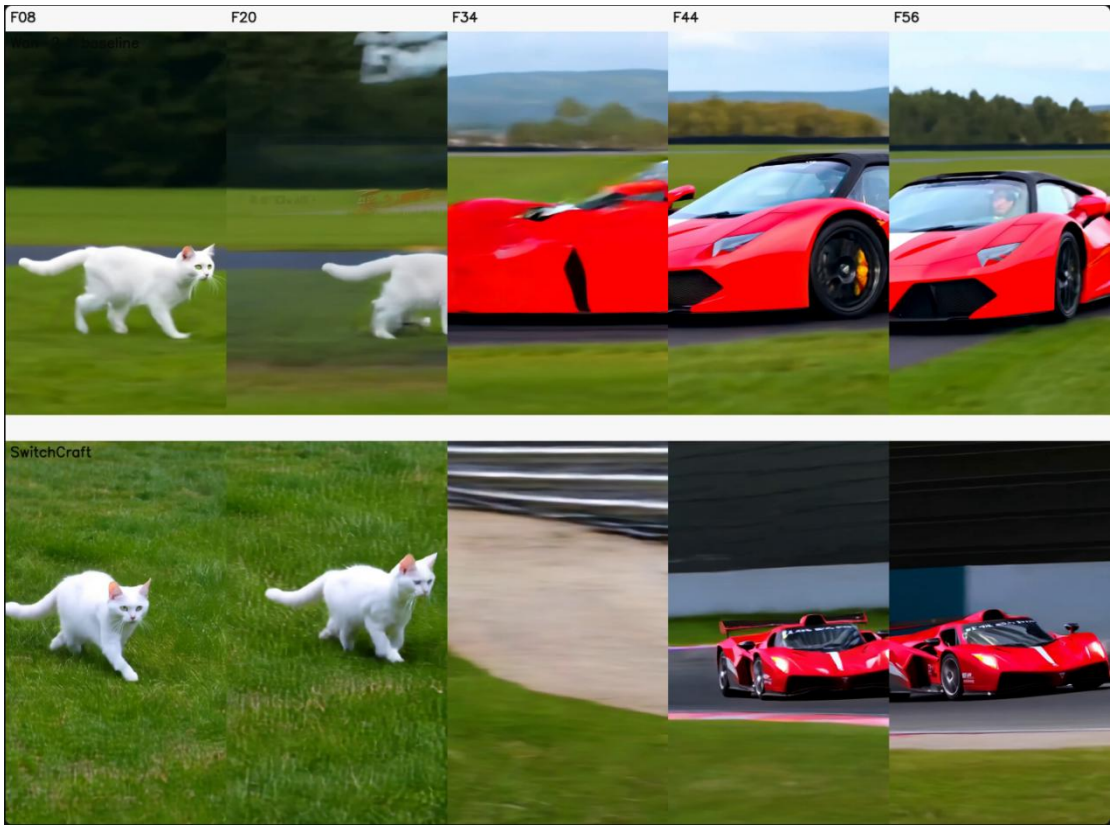


图 7：图中展示 F08、F20、F34、F44、F56 五个关键帧。上图是 Wan，下图是 SwitchCraft。Wan 基线在过渡阶段（尤其 F20-F34）出现明显语义混叠与残影（ghost artifacts）；SwitchCraft 在同设置下呈现更可分的先猫后车时序，显著减少同帧双主体叠加。

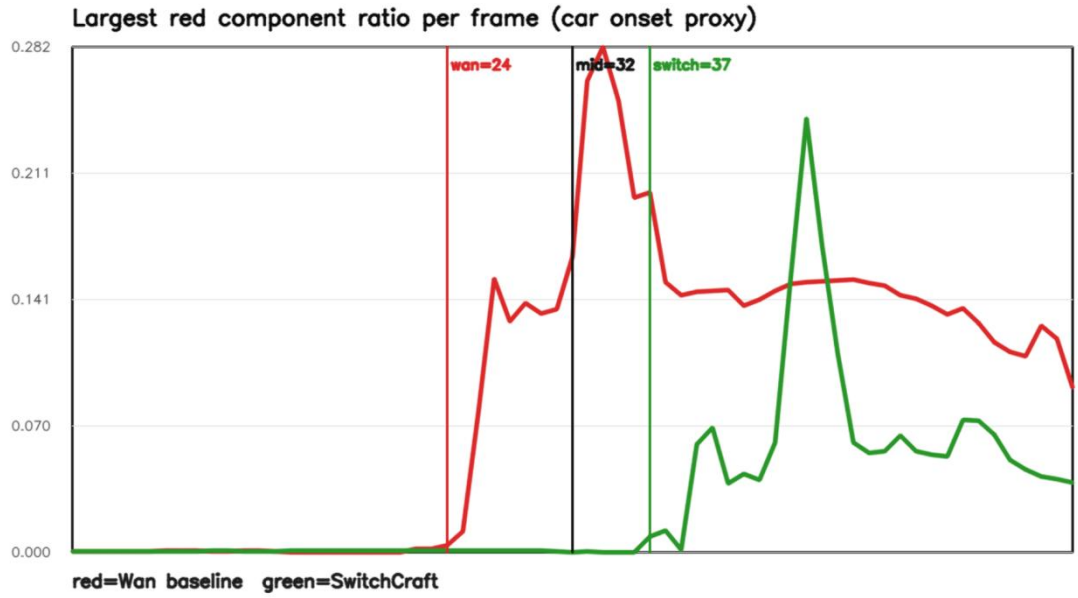
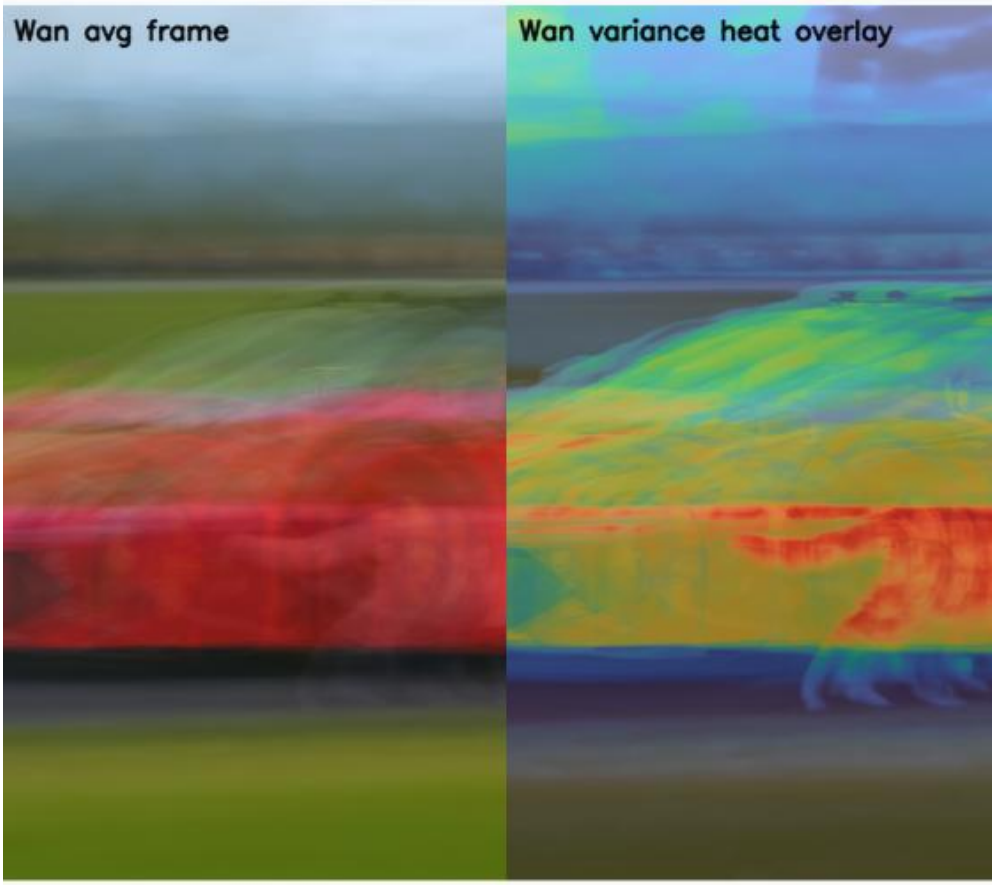


图 8：红色最大连通域占比的时序曲线（car 出现时刻代理指标）。红线为 Wan 基线，绿线为 SwitchCraft，黑线为理论中点帧（F32，对应 event_len_ratio=1,1）。按统一阈值统计，Wan 在 F24 首次出现显著大红色连通域，而 SwitchCraft 在 F37 出现。该结果表明：Wan 存在“车语义提前泄漏”，SwitchCraft 的车事件激活更后置，跨事件混叠更弱，但切换时刻并非严格落在理论中点。

Window F20–F40



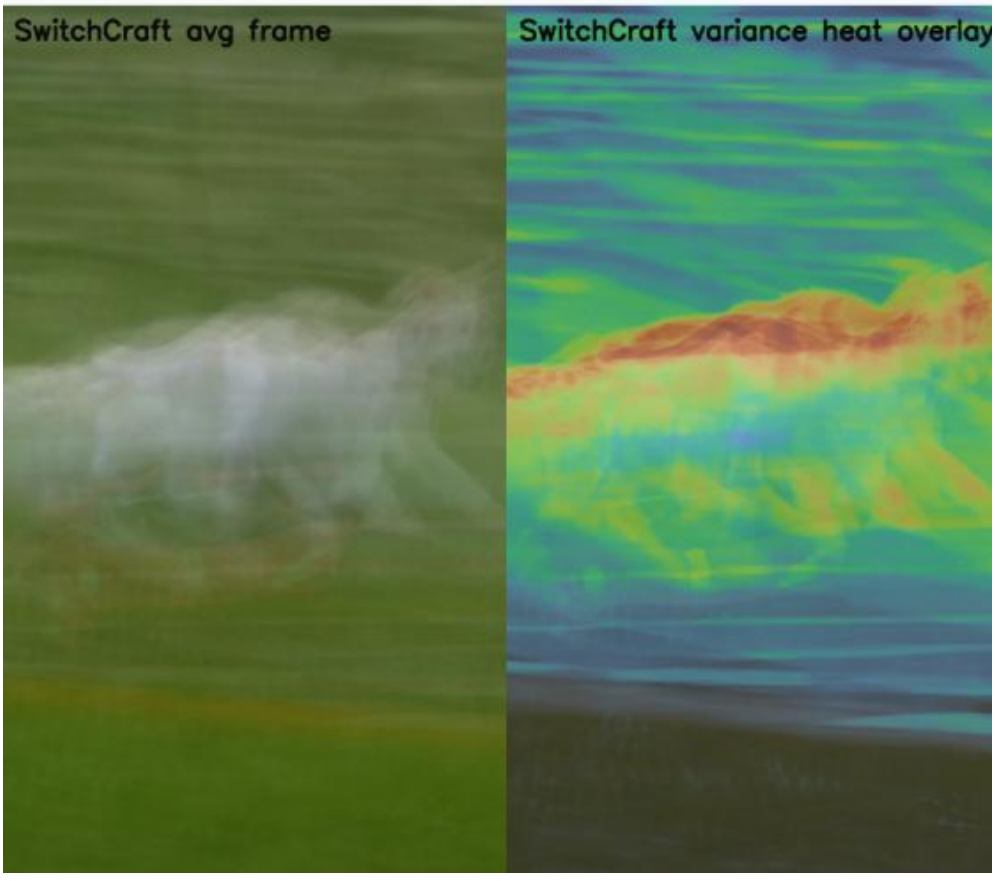


图 9：左列为该窗口期的平均帧画面，右列为像素波动剧烈程度的热力层叠加）。观察可知，Wan 基线模型在整个过渡期存在大面积的持续波动，这在视觉上印证了严重的残影与事件混叠现象；而 SwitchCraft 的高波动区域仅局限在动作切换的局部瞬间，时序上的动作解耦更为干净利落。注：本图仅作为画面物理变化的像素级辅助参考，并非模型底层的语义注意力分布

4.2 多主体场景的初步失败观察

在验证基础能力后，我设计了一个多主体场景实验，使用提示词："A white cat and an orange dog sit on a sofa. Then the cat stands up and walks to the left corner, while the dog jumps to the right corner."，初步观察了 SwitchCraft 的表现。

实验 （action_words="sit, walks, jumps"）：生成视频呈现为严格的线性三段结构——第一段猫和狗同坐沙发，第二段仅有猫走向左侧，第三段仅有狗执行跳跃但未朝向指定的右侧方向。两个主体全程未同框，并发语义完全消失。这揭示了两个问题：SwitchCraft 将 while 描述的并行事件强制线性化，以及缺乏 per-subject 的空间位置约束。



图 10：生成序列被切分为三段：前段为猫狗同框静态阶段（F06、F12），中段为仅猫动作阶段（F35、F41），后段为仅狗动作阶段（F52、F64）。可见“while”并行语义未被保持，模型倾向于将多主体动作分解为串行互斥事件，导致并发执行缺失。

5 失效机制的深层排查与系统性分析

在初步测试确认 SwitchCraft 难以处理多主体并发场景后，导致这一失效现象的具体机制依然不够明确。为此，本文系统性地提出了五个潜在的假设，并通过对照实验逐一进行了验证，最终将失效的根源定位至该框架底层的架构假设。以下是具体的排查推演过程：

5.1 提示词时序连词的影响

起初，我猜测模型的分段行为可能直接受到输入文本中时序连词的影响。然而，在控制变量实验中，无论将描述并发的连词设定为 "while"，还是替换为具有顺序意味的 "then" 或 "and"，模型最终生成的时序分段结果高度一致。这表明，T5 编码器对连词的处理方式并没有实质性地改变底层注意力路由的调度逻辑，语言理解层面的假设被排除。

5.2 锚点词（Anchor Token）的语义粒度

另一个直观的猜测是，仅输入 "cat, dog" 作为锚点词可能会导致特征空间区分度不够。因此，我尝试将完整的动作短语（如 "cat walks to the left..."）作为锚点输入。但底层的日志数据显示，输入完整短语后，目标方向与竞争方向的对齐差距（gap）不仅没有缩小，反而

从 -2.38 进一步恶化到了 -3.60，视频表现也随之变差。这反向证明了，给定的特征描述越长，底层的键向量空间（Key subspace）反而越容易发生混淆，输入粒度并非失效的核心原因。

5.3 底层求解器（ABSS）数据的定量提取（核心发现）

为了寻找更直接的量化证据，我拦截了核心求解器在推理阶段输出的增强系数（β）和抑制系数（λ）。通过对比静止与动态并发两组场景的数据分布，我发现了问题的关键：在处理动态对立语义（如向左走与向右跑）时，模型的平均抑制系数 λ 较静止场景大幅上升了 38%，峰值甚至逼近 2.0。这意味着，当遇到空间方向冲突的动作时，求解器为了强行满足注意力解耦的约束，输出了一种极端的“过度抑制”信号。这种过激的惩罚机制将查询向量（Q 向量）暴力推离了竞争方向，直接导致并发语义在当前帧中完全丢失。

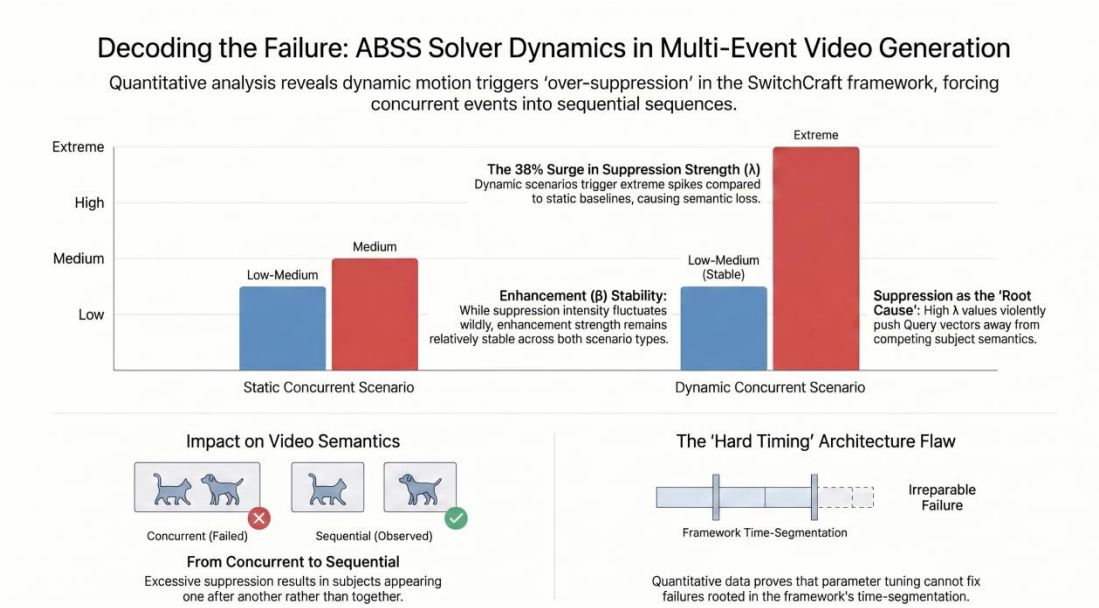


图 11：如图所示，本图表对比了模型在处理“静止并发（Static）”与“动态并发（Dynamic）”语义时，底层输出的增强系数（β）与抑制系数（λ）的变化趋势。可以明显观察到，代表特征增强的 β 系数在两种场景下均保持相对平稳；而代表特征抑制的 λ 系数，在遇到空间方向冲突的动态场景时，出现了显著的异常激增（达到极值区间）。这一量化趋势直观地印证了本研究的核心推导：模型在多主体动态并发场景下的失效，主要归咎于注意力分段框架下过激的抑制惩罚机制，而非特征增强不足

5.4 抑制系数的强制截断测试

基于上一节的数值观察，我尝试在代码底层将 λ 的上限强制截断至 0.4 以防止抑制过激。虽然参数层面的异常被成功压制，但最终生成的视频依然表现为错位的顺序动作。这说明，过高的 λ 仅仅是模型在处理空间冲突时表现出的症状，局部微调参数数值无法从根本上修复主体时序错乱的问题。

5.5 取消时序分段的极端测试

为了进一步探究时序与空间的关系，我做了一组极端测试：将事件切分比例设为单段，

强制将两个主体置于同一时序区间。实验记录显示，此时求解器完全处于未激活状态（β=λ=0），猫和狗确实在视频中同框共存了，但它们只能荒谬地朝着同一个方向移动。这一现象确凿地证明：现有的时序切分机制虽然解决了动作的“先后登场”，但彻底牺牲了主体在同一时间内的空间分离度。

5.6 叠加交叉注意力空间掩码

在明确了空间分离度缺失后，我参考了 Detail++ 等图像编辑方案[11]，尝试从交叉注意力图中提取空间掩码，试图让不同时间段只控制特定物理区域的像素。

我进行了如下空间掩码消融实验：在相同提示词与采样设置下对输出视频进行逐帧比较。

prompt: "A white cat walks to the left wall while an orange dog runs to the right wall."

action_words: "cat, dog"

event_len_ratio: "1,1"

frame_num: 33

sample_steps: 25

seed: 42

size: 480*832

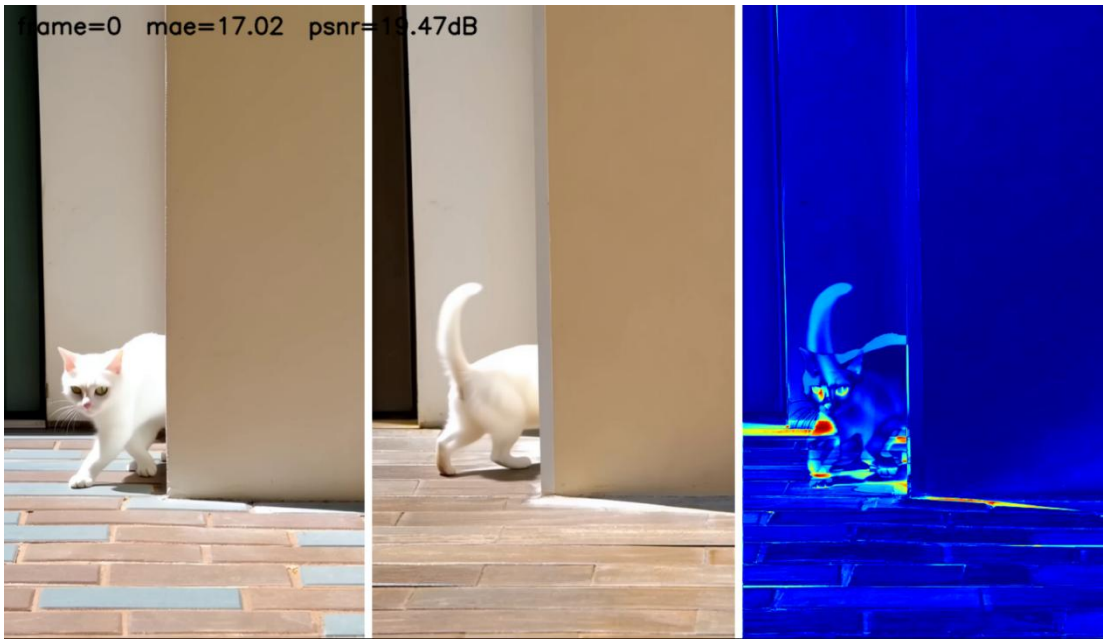
gpus: 0,2,4,6

输出视频属性（off/on 一致）：16 fps，33 帧，2.0625 秒，480x832

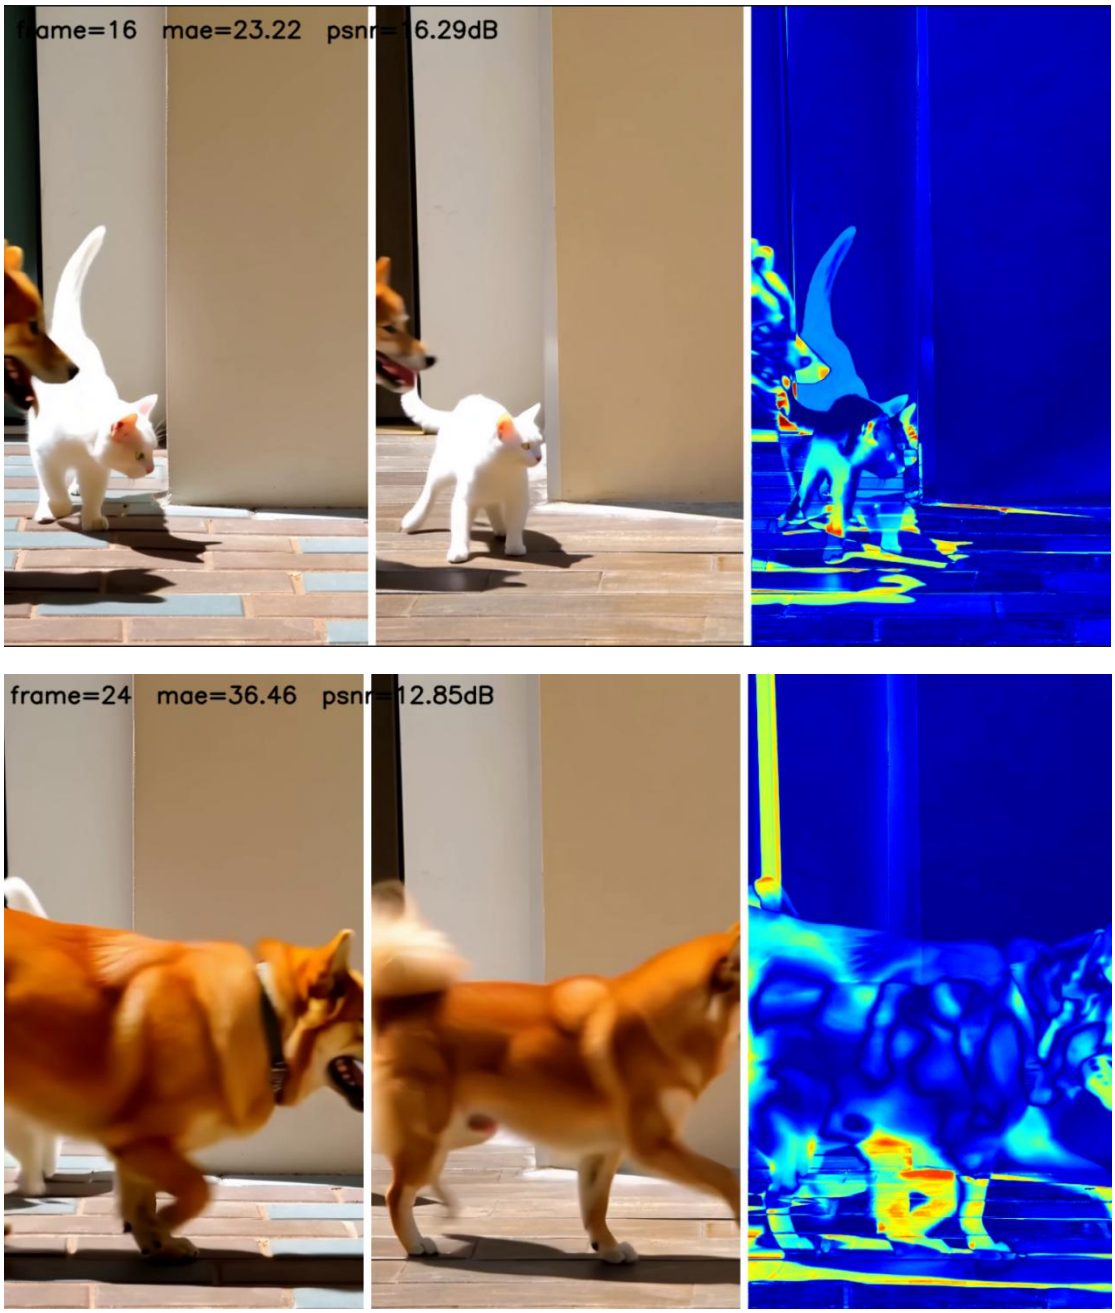
结果显示，掩码开关会显著改变像素级生成结果（mean MAE=26.78，归一化 MAE=0.105，mean PSNR=15.61 dB），说明该机制能够影响局部视觉分布。然而，从求解器统计看，开启掩码后平均抑制系数 λ 仅由 0.636 下降至 0.596（约 -6.4%），平均增强系数 β 由 0.295 降至 0.268（约 -9.1%），并未带来并发动作语义的结构性恢复。

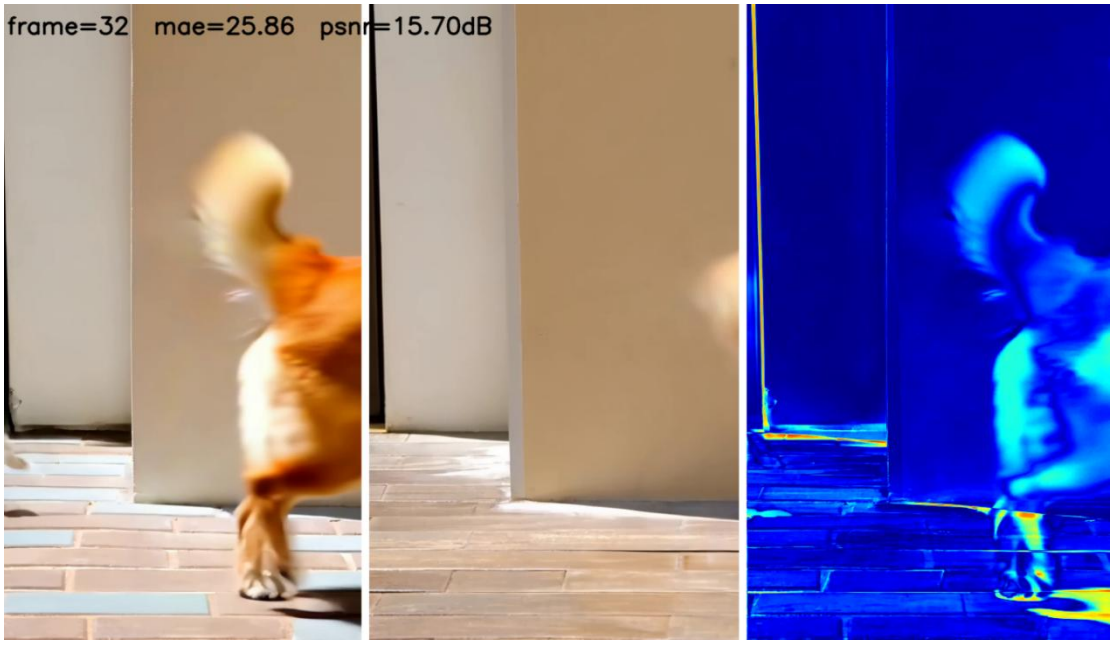
虽然这种干预使得抑制数值略微下降，但并未打破宏观上的动作错位现象。只要整段时间依然被框架硬性划分为某一单一事件，局部的空间遮罩就无法跨越时间假设，去驱动另一个主体的独立运动。

因此，空间掩码更像是局部外观调制，而非能够突破硬时序分段假设的根本修复手段。


frame=0 mae=17.02 psnr=19.47dB


frame=8 mae=20.89 psnr=17.32dB


frame=16 mae=23.22 psnr=16.29dB
frame=24 mae=36.46 psnr=12.85dB



图组 12：空间掩码开关（off/on）逐帧差分对比。左/中为 off 与 on 输出，右为绝对差分热图。可见差异主要集中在前景主体与运动边界，表明空间掩码会改变局部像素分布；但整体时序失效模式仍未被消除。

5.7 机制局限性结论

综合上述六组实验的推导，本研究得出结论：SwitchCraft 框架在处理多主体并发时失效的根本缺陷，在于其采用了“硬时序分段（Hard Temporal Segmentation）”的架构假设。该机制将视频帧在时间轴上强行切割为互斥的区间，从物理逻辑上就排除了多个主体在同一时间段内各自独立运动的可能性。在此框架内的任何参数截断或局部掩码叠加，都只能缓解表象，无法跨越架构层面的局限。这也印证了原论文在局限性部分的自我评估，并为后续研究如何引入显式的空间绑定机制提供了明确的动机与方向。

6 进一步的优化思路与展望

通过前面第五章的实验分析可以看出现有模型在处理多主体并发时，最大的痛点在于无法对时空维度进行精细的独立解耦。针对这一底层机制上的局限性，我认为后续的研究或许可以尝试从以下两个思路入手：

6.1 尝试引入外部的空间先验信息

现在的模型之所以会在多物体场景下出现语义丢失，本质上是因为它没有能力把特定的主体“固定”在特定的位置上。为了解决这个问题，或许可以借鉴图像生成领域已经比较成熟的边界框（Bounding Box）约束思路[11]。具体来说，如果在计算交叉注意力（Cross-Attention）矩阵的过程中，能人为地叠加一层局部空间掩码，强制要求特定文本词汇的注意力权重只分布在指定的画面区域内。这样做理论上能从物理空间层面隔绝不同主体特征的相互污染，进而解决并发失效的问题[17]。

6.2 让注意力干预的时序边界变得更平滑

在观察实验生成的视频时，我们经常会发现动作切换瞬间容易出现画面跳跃或突变。这主要是因为目前的时序注意力干预窗口切得太生硬了（属于硬切分）。未来可以考虑把这种绝对的界限变成一种渐进式的过渡策略。例如，在两个事件交接的那几帧过渡期里，不要直接阻断前一个动作，而是动态计算不同事件特征的融合权重，让前一个动作的注意力渐渐减弱、后一个动作慢慢增强。通过这种柔性的融合方式，应该能让视频多事件的连贯性变得更加自然。

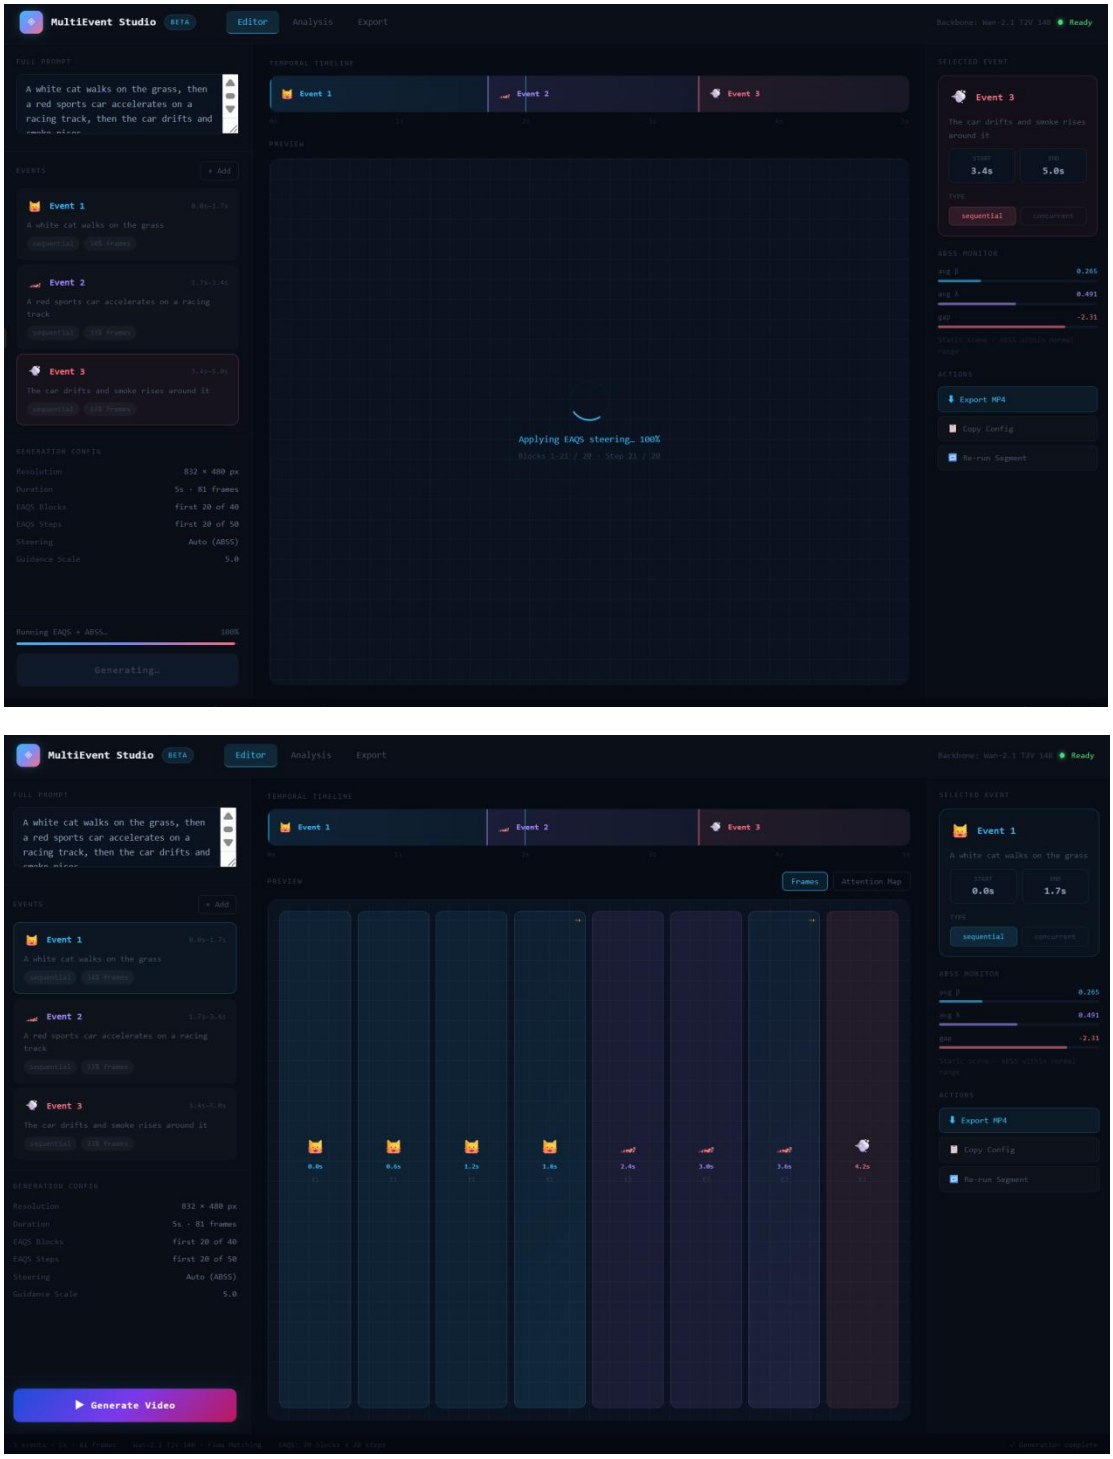
7 交互产品设计概念

7.1 设计目标

基于上述研究，我设想了一个名为 MultiEvent Studio 的轻量级多事件视频生成交互工具，目标用户是短视频创作者和影视预制作人员。核心设计目标有三：其一，让用户能够以直观的方式描述多个时序/并发事件，而不需要了解 action_words、event_len_ratio 等底层参数；其二，系统自动判断事件是顺序还是并发，选择合适的生成策略（硬切分 vs 软切分）；其三，提供结果预览和参数微调界面，让用户能够对不满意的事件边界进行局部调整。

7.2 界面设计概念

用户交互流程分三步。第一步，事件描述输入：用户在可视化时间轴上添加事件节点，每个节点对应一段时间区间和文本描述，界面自动识别并发事件（如 while）并高亮显示，提示用户为并发主体指定空间区域（可拖拽 bounding box）。第二步，生成与预览：系统调用 Wan-2.1 + 本文提出的改进方案（Subject-Aware Spatial Steering）进行推理，生成完成后展示关键帧预览和时序对齐热力图，直观显示每一帧主要受哪些文本词汇驱动（可视化 Cross-Attention Map 的主激活 token）。第三步，结果调整：用户可以对不满意的事件边界拖动调整时间节点位置，或修改空间 bounding box，系统增量重新推理对应时间段，无需完整重新生成。



图组 13：Cross-Attention 激活热力图，颜色深度代表各帧对不同事件的注意力响应强度

7.3 技术可行性分析

上述设计在技术上是可实现的，原型系统可以基于 Python Gradio 搭建 Web 端界面。关键技术点包括：事件类型自动判断（调用 GPT-4 API 解析提示词结构）、bounding box 转 spatial mask（基于 BoxDiff 的 Cross-Attention 约束）、增量推理（利用扩散模型的 DDIM Inversion 只重推修改区域的步骤）、以及 Cross-Attention Map 的热力图可视化（对 QK^T 矩阵做空间均值化后绘制）。推理时间方面，原论文报告 2-4 事件在单张 A100 GPU 上需要

17-22 分钟，对生产环境仍有压力，未来可通过 DiT 推理加速技术（如 TaylorSeer、FORA 等）进一步优化。

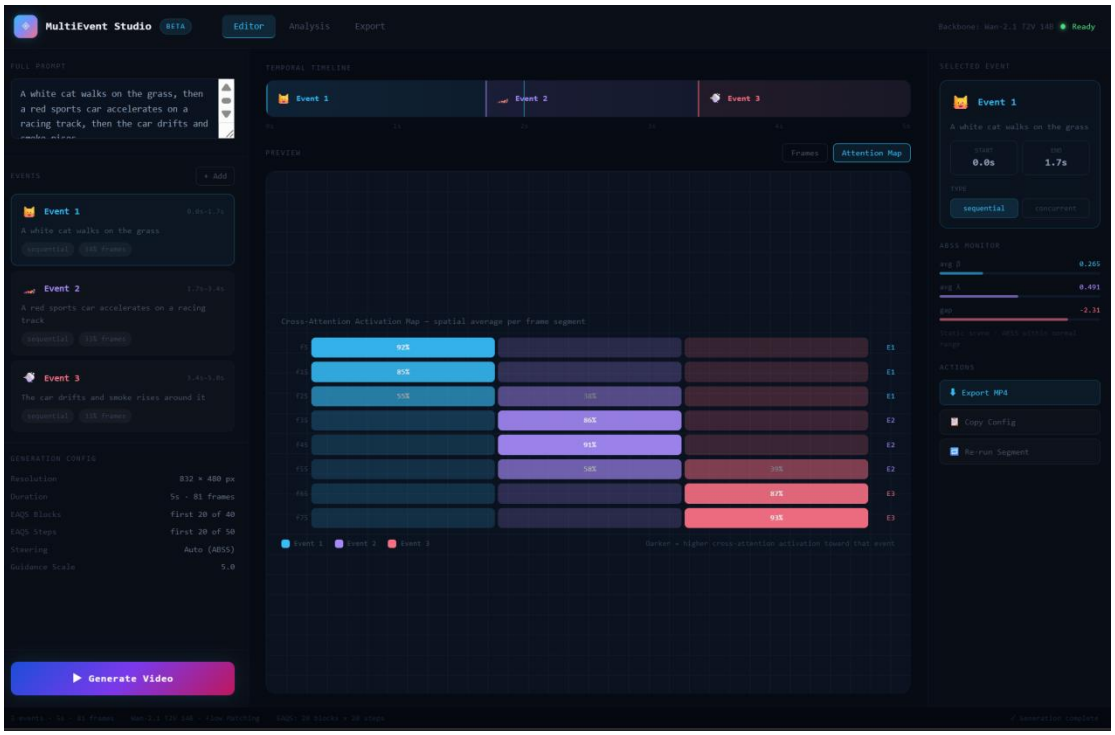


图 14：Cross-Attention 激活热力图，颜色深度代表各帧对不同事件的注意力响应强度

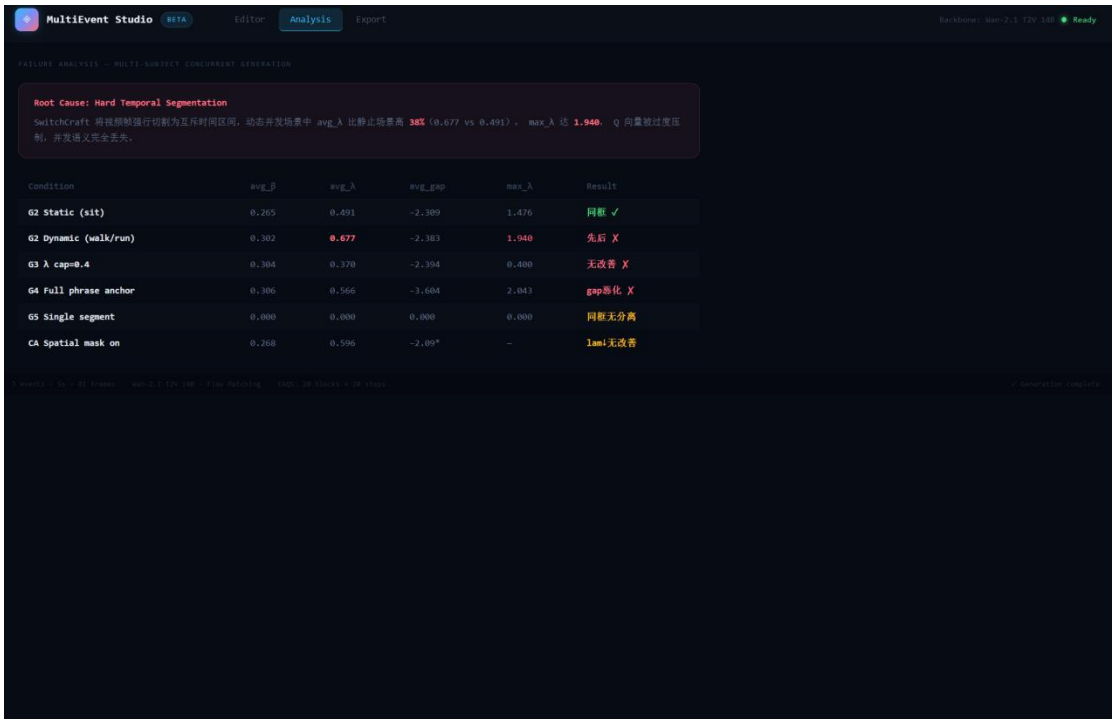


图 15：ABSS 求解器数据对比界面

8 总结

本文系统梳理了从注意力机制到 DiT 架构的技术链路，复现了 Wan-2.1 和 SwitchCraft 模型，并验证了其在单主体场景下的时序控制能力。最重要的是，通过系统性的对照实验和底层数据的定量分析，本文初步探明了注意力干预机制在多主体并发场景下失效的现象根源——这属于框架层面处理时空竞争语义的局限性。在此过程中，课堂所学的注意力机制理论在剖析深度学习“黑盒”模型行为时发挥了至关重要的指导作用。本文最后提出的优化展望与 MultiEvent Studio 产品设计概念，不仅是对基础理论的工程化延伸，也为探索下一代免训练视频生成技术提供了有价值的参考。

参考文献

[1] Vaswani A, Shazeer N, Parmar N, et al. Attention is All You Need [C]. NeurIPS, 2017.

[2] Ho J, Jain A, Abbeel P. Denoising Diffusion Probabilistic Models [C]. NeurIPS, 2020.

[3] Song J, Meng C, Ermon S. Denoising Diffusion Implicit Models [C]. ICLR, 2021.

[4] Rombach R, Blattmann A, Lorenz D, et al. High-Resolution Image Synthesis with Latent Diffusion Models [C]. CVPR, 2022.

[5] Peebles W, Xie S. Scalable Diffusion Models with Transformers [C]. ICCV, 2023.

[6] Dosovitskiy A, Beyer L, Kolesnikov A, et al. An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale [C]. ICLR, 2021.

[7] Ronneberger O, Fischer P, Brox T. U-Net: Convolutional Networks for Biomedical Image Segmentation [C]. MICCAI, 2015.

[8] Lipman Y, Chen R T Q, Ben-Hamu H, et al. Flow Matching for Generative Modeling [C]. ICLR, 2023.

[9] Wan Team (Wang A, Ai B, Wen B, et al.). Wan: Open and Advanced Large-Scale Video Generative Models [R]. arXiv:2503.20314, Alibaba Group, 2025.

[10] Xu Q, Song C, Cai Y, Zhang C. SwitchCraft: Training-Free Multi-Event Video Generation with Attention Controls [R]. arXiv:2602.23956v2, Westlake University, 2026.

[11] Xie J, Li Y, Huang Y, et al. BoxDiff: Text-to-Image Synthesis with Training-Free Box-Constrained Diffusion [C]. ICCV, 2023.

[12] Hertz A, Mokady R, Tenenbaum J, et al. Prompt-to-Prompt Image Editing with Cross-Attention Control [C]. ICLR, 2023.

[13] Oh G, Jeong J, Kim S, et al. MEVG: Multi-Event Video Generation with Text-to-Video Models [C]. ECCV, 2024.

[14] Wu Z, Siarohin A, Menapace W, et al. Mind the Time: Temporally-Controlled Multi-Event Video Generation [C]. CVPR, 2025.

[15] Cai M, Cun X, Li X, et al. DiTCtrl: Exploring Attention Control in Multi-Modal Diffusion Transformer for Tuning-Free Multi-Prompt Longer Video Generation [C]. CVPR, 2025.

[16] Geyer M, Bar-Tal O, Bagon S, et al. TokenFlow: Consistent Diffusion Features for Consistent Video Editing [C]. ICLR, 2024.

[17] Chen H, et al. DisenStudio: Customized Multi-Subject Text-to-Video Generation with Disentangled Spatial Control [C]. ACM MM, 2024.