基于个性化模态门控与抗坍缩融合的多模态点击率预测方法

数学建模课程大作业

摘要

在多模态推荐场景中，物品往往同时具备文本描述、图像封面、结构化属性以及预训练内容嵌入等异质信息，如何在建模用户兴趣的同时有效融合这些互补信号，是提升点击率预测精度的核心难点。本文以 WWW2025 MM-CTR Challenge 的 Task2 为实验平台，提出 ACMF-PMG-DIN。模型在 DIN 目标注意力的基础上捕获与候选物品相关的用户历史兴趣，并通过个性化多模态门控为每个 user-item 样本动态分配模态权重。训练中门控权重向优势模态过度集中的现象（即门控坍缩）是多模态融合的常见陷阱，本文为此引入先验平滑加以约束，并进一步设计抗坍缩多模态融合机制（ACMF）——由模态级深监督（MDS）与早–晚互补融合（ELF）两部分构成，分别赋予弱模态独立的训练梯度与预测旁路。在验证集上，ACMF-PMG-DIN 的 AUC 达到 0.982644，Logloss 降至 0.154708，相较基础模型 PMG-DIN 分别改善 0.001429 与 0.029949。将最终模型提交至 Codabench 官方评测平台后，测试集 AUC 为 0.9853，在 MM-CTR Challenge Task2 排行榜中位列第 13 名，表明所提方法在独立测试数据上仍具有较强竞争力。消融实验表明，MDS 的主要贡献在于增强排序判别力，ELF 在 MDS 的监督约束下为主路径提供稳定的校准补偿；二者协同时方能兼顾排序与校准，分别单独使用则效果均不理想。模态消融进一步揭示，属性模态是当前数据集中最关键的判别信号，文本与图像对预测概率稳定性的贡献虽较隐性，却可从 Logloss 的变化中清晰量化。

关键词：点击率预测；多模态推荐；DIN；个性化门控；模态坍缩；早晚融合

1 引言

点击率预测作为推荐系统的核心评分任务，要求模型在给定用户、候选物品及上下文的条件下准确估计点击概率。这一概率不仅决定候选物品在排序阶段的相对位次，还直接影响召回过滤、广告竞价与流量分配等下游决策。近年来，内容推荐与电商平台中的物品往往同时附带标题文本、封面图像、类目属性以及预训练多模态嵌入等多种信息形式，充分利用这些异质信号的互补性，已成为提升 CTR 预测质量的重要切入点。

多模态 CTR 预测面临两类相互关联的挑战。一方面，用户的兴趣偏好具有明显的目标依赖性：历史交互序列中并非每条记录都与当前候选物品同等相关，从序列中精准抽取目标相关的兴趣信号是用户建模的关键。DIN [1] 通过目标注意力机制对历史行为动态加权聚合，有效应对了这一问题，并已在工业推荐系统中得到广泛验证。另一方面，不同模态的判别能力存在显著不均衡——结构化属性通常携带直接、稳定的点击相关信号，在优化过程中自然占据主导地位，而文本、图像等内容型模态的信号较为间接，容易在竞争中被边缘化。当个性化门控缺乏约束时，其权重分布会逐渐退化为对优势模态的单一依赖，我们将这一现象称为门控坍缩，其后果是多模态融合名存实亡，弱模态既缺乏有效的训练梯度，也缺少独立的预测贡献通道。

本文的思路是在保留 DIN 用户兴趣建模能力的前提下，通过结构性机制防止弱模态的参与空间被完全压缩。ACMF-PMG-DIN 沿三个递进层次展开：以个性化多模态门控生成样本级融合权重，为每个 user-item 对提供定制化的模态偏好表达；以先验平滑限制门控分布的尖锐程度，在保持优势模态主导地位的同时为弱模态留出稳定权重；进而以 ACMF 机制借助 MDS 使弱模态 logit

head 在训练阶段获得直接监督，借助 ELF 在推理阶段为这些受约束的旁路信号保留加权输入通道。这一设计并不以强制均衡各模态贡献为目标，而是以结构性约束让每个模态在其信息价值所能支撑的范围内充分发挥作用。

实验从多个维度验证了上述设计的有效性。属性模态的不可替代性体现在其被移除后 AUC 与 Logloss 的剧烈下降；文本与图像的价值则更多通过 Logloss 的变化加以体现，这与两者在联合建模中扮演" 概率校准辅助" 而非" 排序判别主力" 的角色相吻合。MDS 与 ELF 的协同组合在所有变体中取得了最均衡的排序–校准折衷，而两者分别单独使用时均存在明显的单侧缺陷，二者的互补关系在消融实验中得到了充分印证。最终模型在 Codabench 测试集上的 AUC 达到 0.9853，在官方排行榜中排名第 13，进一步说明该方法在赛题设定下具有较好的实际预测效果。

本文的贡献归纳如下：

1. 提出 ACMF-PMG-DIN，将 DIN 目标兴趣建模、个性化多模态门控、先验平滑与抗坍缩融合机制整合为一套结构清晰、逐级约束的多模态 CTR 预测框架；
2. 分析门控坍缩的成因与表现，提出 MDS 与 ELF 两种互补应对机制——前者在训练阶段为弱模态提供独立监督约束，后者在推理阶段为受监督的旁路信号保留预测通道，二者结合方能兼顾排序与校准；
3. 通过组件消融、模态消融、门控分布可视化以及 late fusion 权重分析，对各模块的作用机制及其对 AUC 与 Logloss 的不同影响路径给出系统性的经验解释。

2 项目简介与任务定义

2.1 项目背景

本项目来源于 WWW2025 EReL@MIR Workshop 举办的 MM-CTR Challenge [5] 中的多模态点击率预测任务，数据集采用 MicroLens [4] 短视频推荐场景中的用户交互与物品多模态信息。赛题面向真实推荐场景，要求模型在用户历史行为和目标物品多模态信息的基础上预测点击概率。整体任务包含两个阶段：Task1 生成固定维度的 item embedding，Task2 基于用户历史、目标物品及多模态特征进行 pCTR 预测。本文聚焦 Task2，不将 Task1 embedding 的生成作为主要贡献，而是将其视为固定内容表征输入。

Task2 的输入可以概括为三类：用户侧信息、目标物品信息和多模态物品特征。用户侧信息主要体现为历史交互序列；目标物品信息包括物品标识及其 embedding；多模态特征包括文本、图像、属性以及 item embedding。输出为用户点击目标物品的概率 $\hat{y} \in (0,1)$。训练标签 $y \in \{0,1\}$ 表示是否发生点击。

2.2 评价指标

本文采用 AUC 与 Logloss 作为主要评价指标。AUC 衡量模型对正负样本的排序能力：若模型对随机抽取的正样本给出高于负样本的预测分数，则 AUC 越高。Logloss 则衡量预测概率与真实标签之间的差异，其定义为

$$\mathcal{L}_{\log} = -\frac{1}{N}\sum_{n=1}^{N}\left[y_n \log \hat{y}_n + (1-y_n)\log(1-\hat{y}_n)\right]. \tag{1}$$

其中 N 为样本总数；$y_n \in \{0,1\}$ 为第 n 个样本的真实点击标签；$\hat{y}_n \in (0,1)$ 为模型对第 n 个样本给出的预测点击概率。AUC 更关注相对排序，Logloss 更关注概率校准。在实际推荐系统中，二者

具有互补意义：排序能力决定候选物品的相对位置，而概率校准影响阈值决策、流量分配和后续收益估计。因此，本文在比较模型时同时报告 AUC 与 Logloss，并在分析中区分排序收益和校准收益。需要说明的是，赛题官方排行榜以测试集 AUC 作为最终排名依据；由于测试集标签不公开，本文的消融实验与机制分析均基于本地验证集完成，测试集结果仅用于报告最终模型的外部评测表现。

2.3 符号说明与建模假设

为便于后续公式的阅读，表 1 汇总了本文涉及的主要符号及其含义，各符号的具体定义将在第 3 节方法部分给出。

表 1: 主要符号说明

符号	含义
u，i	用户，候选（目标）物品
$H_u = \{h_1, \ldots, h_T\}$	用户 u 的历史行为序列，h_t 为第 t 个历史物品的表示
e_i	目标物品的特征表示
h_u	经 DIN 目标注意力得到的用户兴趣表示
$e_{\text{text}}, e_{\text{image}}, e_{\text{attr}}, e_{\text{item}}$	文本、图像、属性、item embedding 四类模态表示
$\mathcal{M}$，M	模态集合 $\{\text{text}, \text{image}, \text{attr}, \text{item}\}$，模态数量 $M = \lvert\mathcal{M}\rvert = 4$
g_p	个性化模态门控权重向量
q	均衡模态先验（各模态权重均为 $1/M$）
λ	个性化门控与均衡先验的混合系数
g	先验平滑后的最终门控权重向量
e_{mm}	门控加权后的多模态融合表示
s_m	模态 m 的单模态 logit（MDS 与 ELF 共用）
w_m，b_m	模态 m 单模态 logit head 的权重向量与偏置
β	MDS 辅助损失的权重系数
π，θ_π	ELF 晚期融合权重向量及其对应的可学习参数
α	ELF 晚期融合支路叠加至主路径的缩放系数
z_{early}，z_{late}，z	早期融合 logit、晚期融合 logit、最终预测 logit
y，$\hat{y}$	真实点击标签，模型预测的点击概率

在此基础上，本文的建模围绕以下四条基本假设展开：

1. 用户对目标物品的兴趣程度可由其历史行为在目标注意力机制下的加权聚合得到，即历史行为对预测的贡献取决于其与目标物品的相关性，而非固定不变；
2. 不同模态信息对点击行为的贡献程度并不均衡：在本文所用数据集中，属性模态通常具有更强的独立判别能力，文本、图像等内容模态的判别能力相对较弱；
3. 判别能力较弱的模态未必对预测无益：其对排序指标（AUC）的边际贡献可能有限，但仍可能通过改善预测概率的分布形态，对概率校准指标（Logloss）产生正向贡献；
4. Task1 阶段产出的 item embedding 在 Task2 建模中被视为固定、不参与训练的输入特征，作为一种稳定的内容先验参与下游点击率预测。

上述符号中的部分超参数在全部实验中取固定取值，汇总如表 2 所示，其具体作用将在第 3 节中结合公式说明。

表 2: 关键超参数取值

参数	说明	取值
M	模态数量	4
λ	个性化门控与均衡先验的混合系数（固定，不参与训练）	0.5
β	MDS 辅助损失权重	0.02
α	ELF 晚期融合缩放系数的初始值（训练中可学习）	0

3 方法

本节介绍 ACMF-PMG-DIN 的完整设计。如图 1 所示，模型由四个功能模块顺序构成：DIN 目标注意力负责从用户历史序列中提取与候选物品相关的兴趣表示；个性化多模态门控（含先验平滑）为每个 user-item 样本动态生成模态融合权重；早期融合主路径将加权后的多模态表示与用户兴趣拼接后送入 DNN 得到主 logit；MDS+ELF 辅助路径则为各模态单独施加训练监督，并在推理阶段以可学习权重将单模态 logit 轻量叠加至主预测。四个模块递进设计，共同作用于最终的点击概率估计。

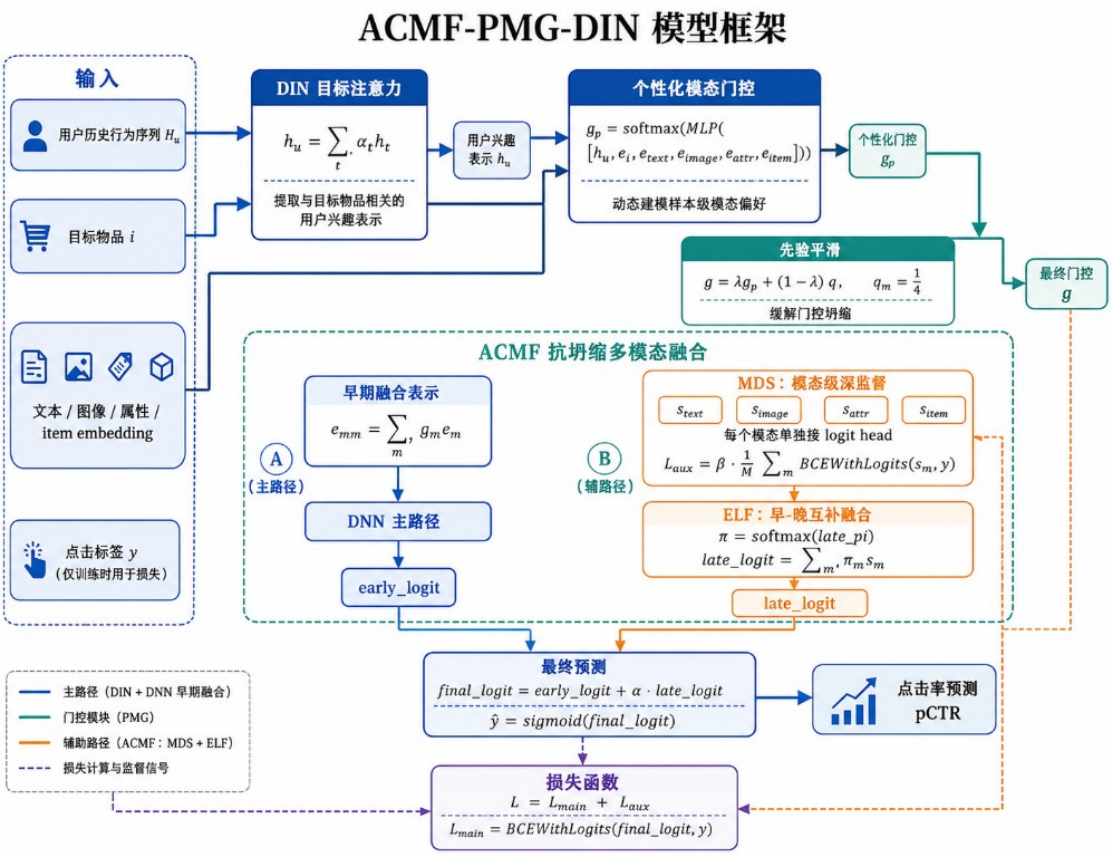


图 1: ACMF-PMG-DIN 模型框架。蓝色主路径为 DIN 目标注意力与门控早期融合后经 DNN 得到 `early_logit`；橙色辅助路径为 MDS 单模态深监督与 ELF late fusion；最终预测为二者加权组合。

3.1 问题建模与优化目标

本文的建模目标可表述为：在给定用户 u 的历史行为序列 H_u 与目标物品 i 的多模态特征的条件下，构造预测函数 $f(\cdot)$，使其输出的点击概率估计

$$\hat{y} = f\left(H_u, e_i, e_{\text{text}}, e_{\text{image}}, e_{\text{attr}}, e_{\text{item}}; \Theta\right) \tag{2}$$

尽可能接近真实点击标签 $y \in \{0, 1\}$，其中 Θ 表示模型的全部可学习参数，包括各模态投影层、注意力网络、门控网络与 logit head 的参数。该问题本质上是一个二分类问题，但本文额外要求预测结果同时满足两方面性质：一是排序性质，即模型对不同样本给出的预测分数应能正确反映样本被点击概率的相对高低，以 AUC 衡量；二是校准性质，即预测概率 $\hat{y}$ 的绝对数值应接近样本的真实点击频率，以 Logloss 衡量。

据此，本文将参数估计问题转化为如下最小化问题：

$$\min_{\Theta} \ \mathcal{L}(\Theta) = \mathcal{L}_{\text{main}}(\Theta) + \mathcal{L}_{\text{aux}}(\Theta), \tag{3}$$

其中 $\mathcal{L}_{\text{main}}$ 是定义在模型最终预测 logit 上的主任务二分类交叉熵损失（具体形式见式 (16)），$\mathcal{L}_{\text{aux}}$ 是本文引入的模态级辅助监督损失（具体形式见式 (15)，其中已包含权重系数 β）。下文各小节将依次给出 $f(\cdot)$ 的具体构造方式，以及 $\mathcal{L}_{\text{main}}$、$\mathcal{L}_{\text{aux}}$ 的完整定义。

3.2 DIN 目标注意力兴趣建模

设用户 u 的历史行为序列为

$$H_u = \{h_1, h_2, \ldots, h_T\}, \tag{4}$$

其中 $h_t \in \mathbb{R}^d$ 表示序列中第 t 个历史物品的特征表示（由物品 ID、标签等特征经嵌入层编码后拼接而成），T 为历史序列长度。目标物品（即当前待预测是否被点击的候选物品）的特征表示记为 $e_i \in \mathbb{R}^d$。DIN [1] 的核心思想是根据目标物品对历史行为赋予不同权重，得到目标相关的用户兴趣，而不是像传统序列模型那样对所有历史行为一视同仁。具体地，对每个历史行为计算一个注意力分数：

$$a_t = f_{\text{att}}(h_t, e_i), \tag{5}$$

其中 $f_{\text{att}}(\cdot, \cdot)$ 是一个以 h_t 与 e_i 为输入、由多层感知机参数化的打分函数，输出标量 $a_t \in \mathbb{R}$，用于衡量历史行为 h_t 与目标物品 e_i 的相关程度。将全部 T 个分数通过 softmax 归一化，得到归一化权重：

$$\alpha_t = \frac{\exp(a_t)}{\sum_{k=1}^{T} \exp(a_k)}, \tag{6}$$

其中求和下标 k 与 t 取值范围相同，均遍历 1 到 T，分母对全部历史位置的分数指数求和，使 α_t 满足 $\sum_{t=1}^{T} \alpha_t = 1$。最终用户兴趣表示由归一化权重对历史行为加权求和得到：

$$h_u = \sum_{t=1}^{T} \alpha_t h_t, \tag{7}$$

其中 $h_u \in \mathbb{R}^d$ 即为与当前目标物品相关的用户兴趣表示，作为后续模态门控与最终预测的用户侧输入。

3.3 个性化多模态门控

目标物品由四类模态表示描述：文本表示 e_{text}（源自预训练语言模型编码得到的标题/描述语义嵌入 [2]）、图像表示 e_{image}（源自预训练视觉-语言模型编码得到的封面图像嵌入 [3]）、属性表示 e_{attr}（点赞、播放等统计属性经浅层网络映射得到）和 item embedding e_{item}（Task1 阶段产出的固定内容表征）。四类模态构成集合 $\mathcal{M} = \{\text{text}, \text{image}, \text{attr}, \text{item}\}$，模态数量 $M = |\mathcal{M}| = 4$。不同样本对模态的依赖并不相同，因此本文引入个性化模态门控，其设计思路借鉴了多任务学习中样本级路由的混合专家机制 [6]，基于用户兴趣和目标物品的多模态特征生成样本级模态权重：

$$g_p = \text{softmax}\left(\text{MLP}\left([h_u, e_i, e_{\text{text}}, e_{\text{image}}, e_{\text{attr}}, e_{\text{item}}]\right)\right), \tag{8}$$

其中 $[\cdot]$ 表示向量拼接操作；$\text{MLP}(\cdot)$ 是一个多层感知机，将拼接后的输入向量映射为 $M = 4$ 维的分数向量；$\text{softmax}(\cdot)$ 对该 4 维分数向量做归一化，输出个性化门控权重向量

$$g_p = [g_{p,\text{text}}, g_{p,\text{image}}, g_{p,\text{attr}}, g_{p,\text{item}}], \qquad \sum_{m \in \mathcal{M}} g_{p,m} = 1, \tag{9}$$

其中下标 m 遍历 $\mathcal{M}$ 中的四种模态，$g_{p,m} \in (0, 1)$ 表示个性化门控赋予模态 m 的权重。给定门控权重后，多模态早期融合表示为对四个模态的表示做加权求和：

$$e_{\text{mm}} = \sum_{m \in \mathcal{M}} g_{p,m} e_m, \tag{10}$$

其中 e_m 表示模态 m 经各自投影层输出的表示（例如 e_{text}、e_{image} 等），e_{mm} 即为融合后的多模态表示。与固定融合权重或简单拼接相比，该门控机制显式建模了样本级模态偏好，使模型能够根据不同用户兴趣和目标物品动态调整每个模态在最终表示中的占比。

3.4 先验平滑与门控坍缩缓解

在多模态推荐中，某些结构化模态可能具有很强的预测能力，导致个性化门控在训练中逐渐集中于该模态。对于当前数据，属性模态表现出明显主导性。如果门控分布过度尖锐，文本、图像和 item embedding 在融合表示中的权重会接近零，从而削弱它们参与训练和预测的机会。本文将这一现象称为门控坍缩。

为缓解该问题，引入均衡模态先验 q：

$$q_m = \frac{1}{M}, \qquad M = 4, \tag{11}$$

即 $q = [q_{\text{text}}, q_{\text{image}}, q_{\text{attr}}, q_{\text{item}}]$ 为四个模态权重相等（均为 0.25）的先验分布。最终门控权重定义为个性化门控 g_p 与均衡先验 q 的凸组合：

$$g = \lambda g_p + (1 - \lambda) q, \tag{12}$$

其中 $\lambda \in [0, 1]$ 用于控制个性化门控与均衡先验之间的混合比例：$\lambda \to 1$ 时 g 趋近于原始个性化门控 g_p，$\lambda \to 0$ 时 g 趋近于均衡先验 q。为简化模型并增强结果的可解释性，本文将 λ 固定为 0.5，即取个性化门控与均衡先验的等权组合，不将其设为可训练参数。平滑后的多模态融合表示为

$$e_{\text{mm}} = \sum_{m \in \mathcal{M}} g_m e_m, \tag{13}$$

其中 g_m 为平滑后赋予模态 m 的最终门控权重。需要强调的是，先验平滑并不是将所有模态强行视为同等重要，而是在保留个性化选择的同时，避免门控分布退化为近似 one-hot 的形式。实验中的门控分布也表明，平滑后属性模态仍保持主导地位，但其他模态获得了稳定的参与空间。

3.5 ACMF：抗坍缩多模态融合

先验平滑从权重层面缓解了门控坍缩：无论个性化门控的原始输出多么集中于某个模态，混合之后的门控权重 g_m 也不会被压低到接近零。但门控权重不仅决定了各模态在融合表示中的占比，也决定了训练阶段反向传播到各模态投影层的梯度大小。在早期融合公式 $e_{\text{mm}} = \sum_m g_m e_m$ 中，模态 m 的表示 e_m 是先乘以门控权重 g_m 再参与后续计算的，因此损失函数关于 e_m 的梯度会包含一个正比于 g_m 的因子：g_m 越小，反向传播回该模态投影层（例如文本投影 text_proj、图像投影 image_proj）的梯度也越小。当某个模态的 g_m 长期处于较低水平（例如先验平滑后的 0.125）时，该模态投影层持续获得的训练信号偏弱，其收敛质量会受到影响，即使门控权重本身没有降为零，该模态的实际学习效果仍可能受限。

针对这一问题，本文设计了抗坍缩多模态融合机制 ACMF（Anti-Collapse Multimodal Fusion），由两个组件构成：模态级深监督（Modality-level Deep Supervision, MDS）在训练阶段为每个模态构造一条不经过门控权重缩放的独立监督通路，使各模态投影层获得的梯度不再受 g_m 大小的限制；早–晚互补融合（Early-Late Fusion, ELF）在推理阶段为这些经过独立监督训练的单模态判别信号构造一条同样不经过门控权重缩放、直接叠加到最终预测 logit 的旁路。两者共享同一组单模态 logit head：该 head 的输出既用于 MDS 的辅助监督损失，也被 ELF 重新用于构造晚期融合分支。

3.5.1 模态级深监督 MDS

对每个模态 $m \in \mathcal{M} = \{\text{text}, \text{image}, \text{attr}, \text{item}\}$，定义一个独立的线性 logit head：

$$s_m = w_m^\top e_m + b_m, \tag{14}$$

其中 $e_m \in \mathbb{R}^d$ 是模态 m 经投影层输出、尚未乘以门控权重 g_m 的原始表示；$w_m \in \mathbb{R}^d$ 与 $b_m \in \mathbb{R}$ 分别是该 logit head 的权重向量和偏置标量，四个模态各自拥有一组独立的 (w_m, b_m)，参数互不共享；$s_m \in \mathbb{R}$ 是仅依据模态 m 自身表示计算得到的预测 logit。由于 s_m 的计算不经过门控权重 g_m，其反向传播梯度大小与 g_m 无关，这是 MDS 能够绕开上述梯度受限问题的关键。

MDS 使用如下辅助损失对每个模态的 logit 施加独立的二分类监督：

$$\mathcal{L}_{\text{aux}} = \beta \cdot \frac{1}{M} \sum_{m \in \mathcal{M}} \text{BCEWithLogits}(s_m, y), \tag{15}$$

其中 $\text{BCEWithLogits}(\cdot,\cdot)$ 表示先对输入 logit 做 sigmoid 变换、再计算二分类交叉熵的复合函数；$y \in \{0, 1\}$ 为样本的真实点击标签；$\beta \in \mathbb{R}_{>0}$ 为辅助损失权重，用于控制该项在总损失中所占的比例；$M = 4$ 为模态数量，除以 M 使各模态在辅助损失中的平均权重相等。模型的主任务损失定义在最终预测 logit z 上：

$$\mathcal{L}_{\text{main}} = \text{BCEWithLogits}(z, y), \tag{16}$$

其中 z 表示模型最终输出的预测 logit：不使用 ELF 时 z 等于下一小节定义的早期融合输出 z_{early}；使用 ELF 时 z 的完整定义见下一小节式中 $z = z_{\text{early}} + \alpha z_{\text{late}}$。整体训练目标为主任务损失与辅助损失之和：

$$\mathcal{L} = \mathcal{L}_{\text{main}} + \mathcal{L}_{\text{aux}}, \tag{17}$$

这一形式与式 (3)中给出的整体优化目标完全一致。实验中取 $\beta = 0.02$，即辅助损失的权重远小于主任务损失（默认权重为 1）。这一取值使 MDS 只提供强度有限的补充训练信号，不改变模型对主任务的主要优化方向：若 β 过大，辅助损失会在优化过程中占据主导地位，使模型过度偏向单模态判别而损害联合建模能力；若 β 过小，辅助监督对参数更新几乎没有影响，MDS 退化为无效模块。

MDS 起作用的具体路径是：模态投影层（如 text_proj、image_proj）的参数同时被主路径和 s_m 的计算使用——e_m 既会乘以门控权重 g_m 参与早期融合，也会直接代入 $s_m = w_m^\top e_m + b_m$ 参与辅助损失。因此，即使某个模态在门控中长期只分到较小权重（如 0.125），其投影层仍能从 $\mathcal{L}_{\text{aux}}$ 中获得一条强度不受 g_m 影响的梯度，从而持续得到训练。需要说明的是，MDS 并不要求 s_m 本身成为一个能独立完成 CTR 预测的强分类器——实验中各模态 signed AUC（定义见式 (22)）普遍只有 0.50–0.57（见表 10），远低于强分类器水平；MDS 的作用范围仅限于保证各模态投影层的训练不因门控权重过小而被抑制，为后续 ELF 提供质量更高的单模态表示。这一在网络中额外增加辅助监督、以更短路径传递梯度的做法与深度监督（deep supervision）[7] 的一般原则一致，区别在于本文将其施加在模态维度而非网络深度维度上。

3.5.2 早–晚互补融合 ELF

MDS 保证了各模态投影层能够获得充分训练，但这些训练好的单模态表示要影响最终预测，在早期融合路径中仍然只能通过门控权重 g_m 起作用：若 g_m 较小，无论 e_m 的表示质量多高，它对最终预测的实际影响也会相应减小。ELF 针对这一点，为每个模态的判别信号构造一条不经过门控权重缩放、直接叠加到最终预测 logit 的旁路。

在多模态学习中，先将各模态原始表示混合再统一决策，通常称为早期融合（representation-level fusion）；而让每个模态先独立给出判断，再将多个判断结果加权合并，则称为晚期融合（decision-level fusion）[8]。本文的主路径属于前者：将用户兴趣 h_u、目标物品表示 e_i、经门控加权的多模态表示 e_{mm} 等拼接后送入一个多层感知机，得到主路径输出的 early logit：

$$z_{\text{early}} = f_{\text{DNN}}([h_u, e_i, e_{\text{mm}}, \cdots]), \tag{18}$$

其中 $f_{\text{DNN}}(\cdot)$ 表示由多层全连接网络参数化的映射函数，$[\cdot]$ 表示对括号内各特征向量做拼接；$z_{\text{early}} \in \mathbb{R}$ 是仅由早期融合主路径给出的预测 logit。

ELF 在此基础上叠加一条晚期融合支路，复用 MDS 中已经训练好的单模态 logit s_m（即每个模态各自独立给出的判断），先通过一组可学习参数计算模态级晚期融合权重，再对各模态判断加权求和：

$$\pi = \text{softmax}(\theta_\pi), \qquad z_{\text{late}} = \sum_{m \in \mathcal{M}} \pi_m s_m, \tag{19}$$

其中 $\theta_\pi \in \mathbb{R}^M$ 是可学习参数向量；$\pi = [\pi_{\text{text}}, \pi_{\text{image}}, \pi_{\text{attr}}, \pi_{\text{item}}]$ 是经 softmax 归一化后的权重向量，满足 $\sum_m \pi_m = 1$，π_m 表示晚期融合阶段赋予模态 m 判断的相对权重；$z_{\text{late}} \in \mathbb{R}$ 是晚期融合支路汇总各模态判断后输出的 logit。需要说明的是，π 与早期融合门控 g 是两组完全独立、分别学习的参数，二者不要求学出相同的模态偏好，实验结果（见表 9）也表明二者确实收敛到了不同的模态权重分布。

晚期融合支路的输出以一个可学习标量 α 加权后，叠加到早期融合的 logit 上，得到模型最终预测 logit：

$$z = z_{\text{early}} + \alpha z_{\text{late}}, \tag{20}$$

其中 $\alpha \in \mathbb{R}$ 为可学习标量，初始化为 0。在训练刚开始时 $z = z_{\text{early}}$，即模型的行为与不含 ELF 的

纯早期融合模型完全一致，晚期融合支路此时对预测不产生任何影响，从而避免在 s_m 尚未训练充分的阶段就让晚期融合支路干扰主路径的学习。随着训练推进，若晚期融合信号能够为主路径提供有益的补充信息，梯度下降会将 α 更新为非零的正值；若晚期融合信号总体上有噪声或无益，α 也可能被更新为接近零甚至负值，以降低晚期融合支路对最终预测的实际影响——例如未使用 MDS 约束的 ACMF-ELF 变体中，训练收敛后的 $\alpha = -0.035$（见表 9）。模型最终输出的点击概率为

$$\hat{y} = \sigma(z), \tag{21}$$

其中 $\sigma(\cdot)$ 表示 sigmoid 函数，将实数域上的 logit z 映射到 $(0, 1)$ 区间，作为最终的点击概率估计 $\hat{y}$。

MDS 与 ELF 在训练与推理两个阶段上的作用是互相配合的：MDS 在训练阶段为每个模态提供不受门控权重影响的独立监督，使各模态 logit s_m 具备有意义的判别性；ELF 在推理阶段为这些 s_m 提供一条不受门控权重影响的加权通路，使其能够实际影响最终预测。仅使用 ELF 而不使用 MDS 时，s_m 缺乏独立监督、判别性较弱，晚期融合支路引入的更多是噪声而非有效信息；仅使用 MDS 而不使用 ELF 时，各模态的判别能力确实得到提升，但这部分能力仅体现在辅助损失中，不会传递到最终预测的 logit 上。二者结合后，训练阶段获得的模态判别能力才能通过推理阶段的晚期融合支路实际影响最终预测——这一点将在实验部分的组件消融结果中给出具体的数值验证。

3.6 算法流程

综合上述各模块，ACMF-PMG-DIN 单个训练批次中的前向计算与参数更新流程可归纳为下方算法 1。该流程与图 1中的模块划分一一对应：步骤 1–3 对应用户兴趣建模与门控生成，步骤 4 对应先验平滑，步骤 5 对应早期融合主路径，步骤 6–7 对应 ACMF 辅助路径，步骤 8 对应联合训练。推理阶段执行相同的前向计算流程（步骤 1–7），仅跳过步骤 8 中的反向传播与参数更新。

算法 1：ACMF-PMG-DIN 前向计算与训练流程

1. **输入编码**：将用户历史行为序列 H_u 与目标物品 i 的原始特征分别编码为 $\{h_t\}_{t=1}^{T}$ 与 e_i，并计算目标物品的四类模态表示 $e_{\text{text}}, e_{\text{image}}, e_{\text{attr}}, e_{\text{item}}$；
2. **用户兴趣建模**：以 e_i 为查询，对历史序列 $\{h_t\}$ 施加 DIN 目标注意力，得到用户兴趣表示 $h_u = \sum_t \alpha_t h_t$；
3. **个性化门控生成**：将 h_u、e_i 与四类模态表示拼接后输入门控网络，得到个性化门控权重 $g_p = \text{softmax}(\text{MLP}(\cdot))$；
4. **先验平滑**：将 g_p 与均衡先验 q 按固定系数 $\lambda = 0.5$ 做凸组合，得到最终门控权重 $g = \lambda g_p + (1 - \lambda) q$；
5. **早期融合**：以 g 对四类模态表示加权求和得到 $e_{\text{mm}} = \sum_m g_m e_m$，与 h_u、e_i 等特征拼接后送入 DNN，得到早期融合 logit z_{early}；
6. **模态级深监督（MDS）**：对每个模态的原始表示 e_m 计算独立的单模态 logit $s_m = w_m^{\top} e_m + b_m$，并计算辅助监督损失 $\mathcal{L}_{\text{aux}}$；
7. **早–晚互补融合（ELF）**：以可学习权重 $\pi = \text{softmax}(\theta_\pi)$ 对 $\{s_m\}$ 加权求和得到 z_{late}，并以缩放系数 α 叠加到主路径，得到最终预测 logit $z = z_{\text{early}} + \alpha z_{\text{late}}$ 与预测概率 $\hat{y} = \sigma(z)$；
8. **联合训练**：计算主任务损失 $\mathcal{L}_{\text{main}}$ 与辅助损失 $\mathcal{L}_{\text{aux}}$，以总损失 $\mathcal{L} = \mathcal{L}_{\text{main}} + \mathcal{L}_{\text{aux}}$ 反向传播，更新模型全部可学习参数 Θ（含 θ_π、α 等；λ 固定为 0.5，不参与训练）。

4 实验

4.1 实验设置

本文实验均在 Task2 上展开，以固定的 item embedding 与多模态特征作为输入，训练过程不使用验证集标签、不采用模型集成、不引入赛题外部数据。优化目标为二分类交叉熵，评估指标为验证集 AUC 与 Logloss，两者分别衡量模型的排序判别力与概率校准质量。实验共分三组：主实验比较不同阶段基线的整体性能；组件消融在 PS-PMG-DIN 基础上逐一引入 MDS、ELF、MDrop 及其组合，以隔离各子模块的独立贡献；模态消融在最终模型上依次移除单一模态，以量化不同模态的信息价值。具体训练配置如表 3 所示。

表 3: 实验设置

项目	取值
训练集规模	3,600,000 条（MicroLens_1M_x1，train）
验证集规模	10,000 条（MicroLens_1M_x1，valid）
历史序列长度上限 T	64
优化器	Adam
学习率	0.001
Batch size	1024
最大 epoch 数	100（配合 early stopping）
Early stopping	patience = 3，以验证集 AUC 为监控指标
硬件环境	单张 NVIDIA RTX 4090 GPU（24GB 显存）
评价指标	AUC、Logloss

4.2 主实验

主实验结果如表 4 所示。ACMF-PMG-DIN 的最终实现采用 MDS+ELF 组合，因此在下文组件消融（表 6）中对应 ACMF-MDS-ELF 变体；表 6 中同时列出仅使用单一组件的 ACMF-MDS、ACMF-ELF，以及叠加 MDrop 的 ACMF-FULL 作为对照，以下各表与分析统一采用这一组变体命名。

表 4: 主实验结果

模型	AUC	Logloss
PMG-DIN	0.981215	0.184657
PS-PMG-DIN	0.981955	0.155866
ACMF-PMG-DIN	0.982644	0.154708

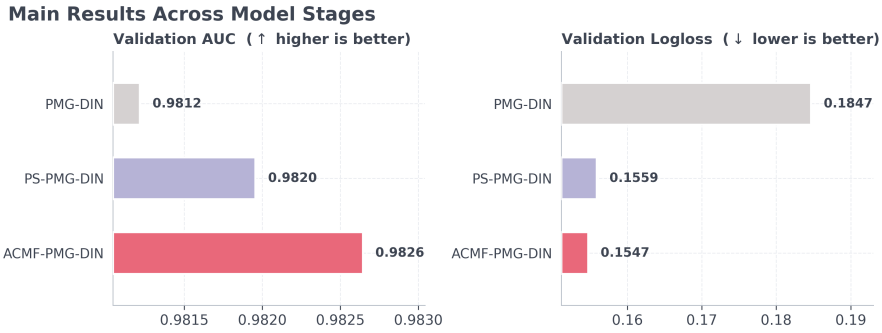


图 2: 主实验 AUC 与 Logloss 对比。

4.3 赛题测试集提交结果

在完成本地验证集上的模型选择与消融分析后，本文将最终模型 ACMF-PMG-DIN 的预测结果提交至 Codabench 官方评测平台（MM-CTR Challenge，Task2 赛道）。赛题以测试集 AUC 作为公开排行榜的唯一排名指标，结果如表 5 所示。

表 5: Codabench Task2 测试集提交结果

项目	取值	说明
测试集 AUC	0.9853	官方排行榜公开分数
排行榜名次	第 13 名	截至 2026-07-02
提交时间	2026-07-02 14:53	Codabench 记录

与表 4 中的验证集结果相比，测试集 AUC（0.9853）高于验证集 AUC（0.982644）。这一差异可能来自测试集与验证集的数据分布不同，也可能与赛题使用私有测试标签进行统一评测有关。由于测试集不提供 Logloss 等额外指标，本文仍以验证集上的 AUC 与 Logloss 联合结果作为模型设计与消融分析的主要依据；测试集 AUC 与排行榜名次则用于说明最终方案在赛题外部评测中的整体竞争力。

4.4 组件消融

ACMF 组件消融结果如表 6 所示。这里的 PS-PMG-DIN 作为不含 ACMF 的基线。

表 6: ACMF 组件消融

变体	AUC	Logloss	说明
PS-PMG-DIN（无 ACMF 组件）	0.981955	0.155866	不含任何 ACMF 组件
ACMF-MDS	0.982904	0.182790	仅模态级深监督
ACMF-ELF	0.981792	0.262135	仅早–晚互补融合
ACMF-MDS-ELF	0.982644	0.154708	MDS + ELF
ACMF-MDrop	0.981267	0.175281	仅模态 dropout
ACMF-FULL	0.980131	0.258090	MDS + ELF + MDrop

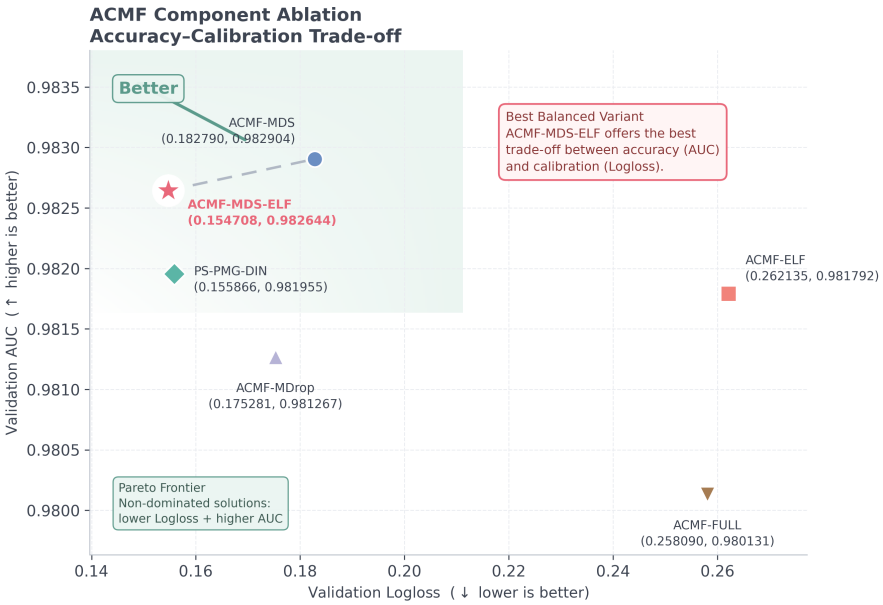


图 3: ACMF 组件消融对比。

4.5 模态消融

最终模型 ACMF-MDS-ELF 的模态消融结果如表 7 所示。

表 7: ACMF-MDS-ELF 模态消融

变体	AUC	Logloss	说明
full	0.982644	0.154708	保留全部模态
no-text	0.982403	0.173380	去掉文本模态
no-image	0.982906	0.177227	去掉图像模态
no-attr	0.967892	0.626674	去掉属性模态

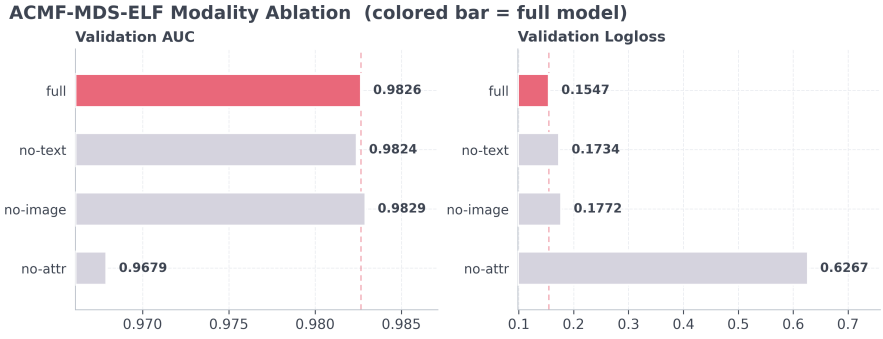


图 4: ACMF-MDS-ELF 模态消融结果。

5 实验结果与分析

5.1 主结果分析

三个基线层级在验证集上的表现如表 4 所示，呈现出一条清晰的递进脉络。PMG-DIN 已具备较强的排序判别力（AUC 0.981215），但 Logloss 高达 0.184657，反映出无约束门控下权重过

度向属性集中，导致预测概率偏离真实分布。引入先验平滑后，PS-PMG-DIN 的 Logloss 骤降至 0.155866（降幅约 16%），AUC 也同步小幅提升至 0.981955。两指标的改善方向一致，但 Logloss 变化量远大于 AUC，说明先验平滑的主要贡献在于概率校准：门控分布从近似 one-hot 恢复到具有合理扩散度后，被压低的弱模态重新参与融合表示的构建，从而稳定了全局概率估计。

在 PS-PMG-DIN 基础上叠加 ACMF 后，ACMF-PMG-DIN 的 AUC 进一步提升至 0.982644，Logloss 降至 0.154708。与前一阶段相比，此轮 Logloss 的改善（0.001158）幅度收窄，而 AUC 的提升（0.000689）则更为突出，说明 ACMF 的贡献更偏向排序能力的增强——这与 MDS 通过辅助监督强化各模态判别梯度的设计初衷一致。值得注意的是，两项指标的同步改善表明，ACMF 并未以牺牲校准为代价换取排序收益，而是在先验平滑所奠定的概率稳定性基础上，提供了额外的结构性增益。进一步地，将最终模型提交至 Codabench 后，测试集 AUC 达到 0.9853，在 Task2 排行榜中排名第 13（见表 5），说明该方案在官方外部评测中同样取得了较好效果。

5.2 ACMF 组件消融分析

组件消融揭示了 MDS、ELF 及 MDrop 三种机制的独立贡献与交互效果，结果见表 6。

单独引入 MDS 后，ACMF-MDS 的 AUC 跃升至 0.982904，成为所有变体中的最高值，但 Logloss 同步升至 0.182790，几乎退回至无先验平滑的 PMG-DIN 水平。这种” 排序提升、校准回退” 的模式说明，辅助损失将额外梯度集中于判别方向，改变了主路径的概率分布，使预测从” 校准型” 偏向” 判别型”。就单一目标而言，若仅关注 AUC，ACMF-MDS 已优于最终模型；但 CTR 预测在实际系统中同时要求准确的概率估计，Logloss 的恶化是难以接受的代价，因此该变体并未入选。

单独引入 ELF 时情况更为严峻：ACMF-ELF 的 Logloss 达到 0.262135，为所有变体之最。根本原因在于，各模态 logit head 在缺乏独立监督时输出高度噪声，late-fusion 旁路将其直接叠加至最终 logit，对主路径概率分布造成难以预期的扰动。负值 $\alpha = -0.035$ 进一步印证了这一点：模型通过负向缩放部分抑制了 late branch 的干扰，却依然无法恢复校准性。这一结果清楚地表明，late fusion 本身并非一种稳健的融合策略，其有效性高度依赖于旁路信号的质量。

将 MDS 与 ELF 联合后，ACMF-MDS-ELF 在 AUC 0.982644 与 Logloss 0.154708 之间取得了所有变体中最均衡的折衷。这一结果与二者的分工关系相符：MDS 为每个单模态 logit head 提供独立训练约束，使旁路输出具备有意义的判别性；在此基础上，ELF 以可学习权重 π 与初始化为零的 α，将旁路信号逐步引入最终预测，避免训练初期主路径受到干扰。MDS 是 ELF 能够稳定发挥作用的前提，ELF 是将 MDS 的监督信号接入最终预测的通道，缺少任意一方均会导致明显的性能缺陷。

MDrop 单独使用（ACMF-MDrop，AUC 0.981267）或与完整 ACMF 组合（ACMF-FULL，AUC 0.980131）均带来性能退化。在属性模态高度主导的特征空间中，随机屏蔽相当于以一定概率切断模型的核心信息通路，引入的训练不稳定性超过了正则化的潜在收益，最终模型因此选择仅保留 MDS+ELF 的组合。

5.3 模态贡献分析

模态消融通过依次移除单一模态，揭示了各模态在排序与概率校准两个维度上的不同贡献机制，结果见表 7。

属性模态的不可替代性是本组实验中最直接的发现。去除属性后，AUC 从 0.982644 骤降至 0.967892，Logloss 从 0.154708 攀升至 0.626674，两项指标均出现数量级意义上的恶化。这与门控坍缩分析相互印证：属性模态之所以能吸引大部分门控权重，正因为它携带了当前数据集中最直接、最稳定的点击判别信号，在其缺失时模型难以找到等效替代，预测质量出现断崖式下滑。

相比之下，移除文本（no-text，AUC 0.982403）或图像（no-image，AUC 0.982906）对排序指标的影响微乎其微，no-image 的 AUC 甚至略高于完整模型。然而两者的 Logloss 均显著恶化，分别升至 0.173380 和 0.177227，这种"AUC 稳定、Logloss 变差" 的分离模式揭示了内容模态的功能定位：它们对正负样本的相对排序贡献有限，但通过联合建模为预测概率的绝对精度提供了稳定化作用。在实际系统中，点击概率估计的准确性直接影响流量分配与出价决策，因此 Logloss 的劣化具有真实的业务含义。no-image 的 AUC 略优并非意味着图像是" 负效益" 模态——更合理的解释是该模态对排序的边际贡献弱于其引入的统计噪声，但这并不妨碍其对 Logloss 的正向贡献。

综上，本文多模态融合的设计理念并非追求所有模态在 AUC 上等量贡献，而是以属性模态承担主要判别划分，文本与图像通过参与联合表示改善概率分布的质量，二者各司其职。

5.4 门控分布分析

表 8 展示了三个模型在验证集上各模态门控权重的均值分布。PMG-DIN 的 personal gate 与 fused gate 均近乎退化为属性模态的单一选择（权重接近 1），是无约束门控自然收敛至最强判别信号的典型表现，与模态消融中属性模态高度主导的观测完全吻合。

引入先验平滑后，PS-PMG-DIN 与 ACMF-MDS-ELF 的 fused gate 均匀分布为属性 0.625、其余三类各 0.125，先验混合的效果清晰可见。值得注意的是，两者在 fused gate 数值上完全相同，但并不意味着模态表示等价。ACMF-MDS-ELF 通过 MDS 为文本、图像和 item embedding 的 logit head 提供了独立训练梯度，在门控权重受约束的条件下，这些模态的单模态表示具有更强的判别意义，从而支撑 late branch 发挥更有效的辅助作用——这一差异无法直接从门控数值中观察，却在 late fusion 权重分析中得到间接体现。

表 8: 模态门控分布对比（验证集平均权重）

模型	门控类型	g_{text}	g_{image}	g_{attr}	g_{item}
PMG-DIN	personal	≈ 0	≈ 0	≈ 1	≈ 0
	fused	≈ 0	≈ 0	≈ 1	≈ 0
PS-PMG-DIN	personal	≈ 0	≈ 0	≈ 1	≈ 0
	fused	0.125	0.125	0.625	0.125
ACMF-MDS-ELF	personal	≈ 0	≈ 0	≈ 1	≈ 0
	fused	0.125	0.125	0.625	0.125

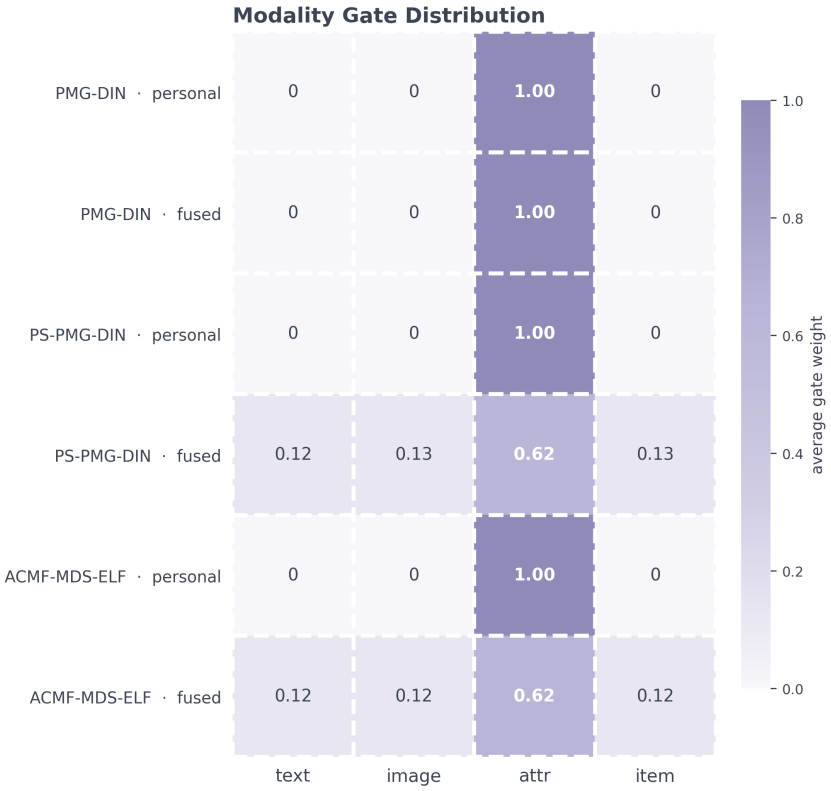


图 5: 不同模型的模态门控分布对比。

5.5 Late Fusion 权重分析

表 9 汇报了三个含 ELF 变体的 late fusion 权重与缩放系数 α。整体来看，$|\alpha| \leq 0.055$，late branch 始终以辅助修正而非主导通路的角色参与最终预测，符合将 α 初始化为零的设计预期——模型仅在旁路信号质量足够高时，才会通过训练学习出非零的正向缩放。

三个模型中，ACMF-ELF 的 α 为负（-0.035），对应最高 Logloss，说明无 MDS 约束时单模态 logit head 的输出质量不足以支撑有益的 late fusion，模型被迫通过负向缩放来减轻旁路的干扰，却仍无法完全恢复校准性。ACMF-MDS-ELF 的 α 最大（$+0.055$），对应最低 Logloss，二者的正相关关系印证了”单模态信号质量越高，late branch 对最终预测的补充越有益”这一推断。

从权重分布看，ACMF-MDS-ELF 中 late branch 对属性模态的权重仅为 0.204，远低于对文本（0.281）和图像（0.273）。与主路径中属性占据 0.625 权重的格局形成鲜明对比，late branch 呈现出明显偏向内容模态的分配。该结果说明，late branch 学到的模态偏好与主路径不同：主路径已充分利用属性信号，late branch 在此基础上更多依赖文本与图像提供补充信息，因而下调了对属性的权重。两条路径在模态偏好上的互补，使最终预测同时兼顾了排序的判别性与概率的校准性。

表 9: late fusion 模态权重 π_m 与缩放系数 α

模型	π_{text}	π_{image}	π_{attr}	π_{item}	α	AUC	Logloss
ACMF-ELF	0.264	0.245	0.247	0.245	-0.035	0.981792	0.262135
ACMF-MDS-ELF	0.281	0.273	0.204	0.241	$+0.055$	0.982644	0.154708
ACMF-FULL	0.264	0.308	0.190	0.238	$+0.043$	0.980131	0.258090

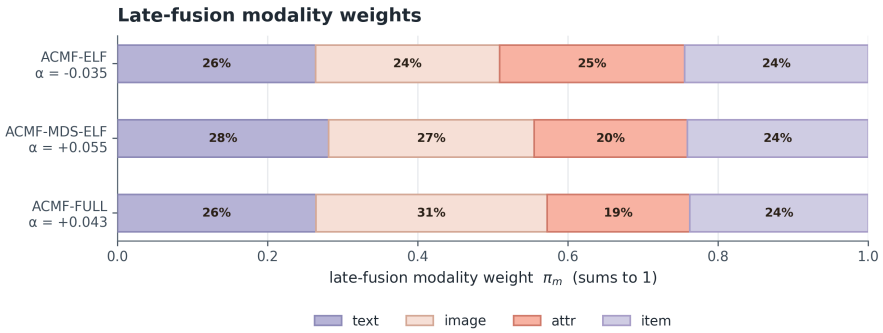


图 6: late fusion 模态权重对比。

为便于直观比较三个变体在四个模态上的权重差异，图 7 以分组柱状图给出了同一组数据的另一种呈现方式，柱高对应表 9中的 π_m 取值。

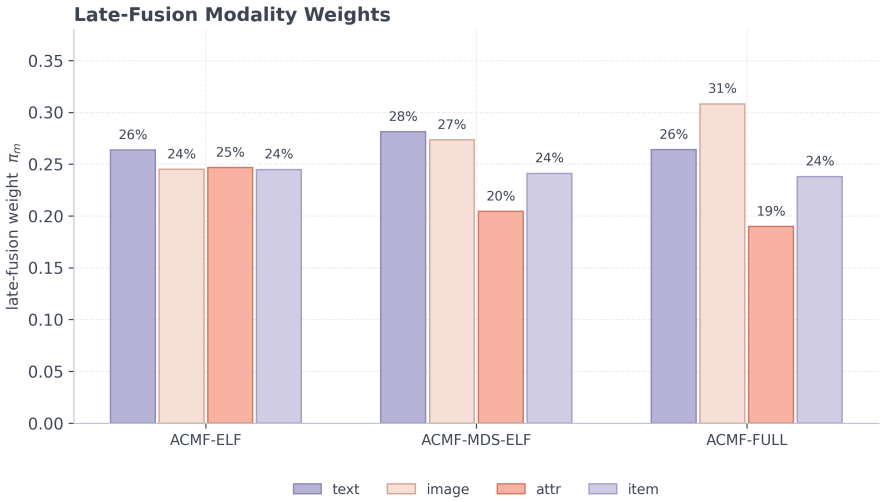


图 7: late fusion 模态权重分组柱状图（与图 6数据一致，仅呈现方式不同）。

5.6 单模态 Logit 分析

表 10 给出了各模态单独 logit 的方向校正 AUC（signed AUC），其定义为

$$\mathrm{SignedAUC}(s_m) = \max\left(\mathrm{AUC}(s_m, y), \mathrm{AUC}(-s_m, y)\right), \tag{22}$$

其中 $\mathrm{AUC}(\cdot, y)$ 表示以括号内的量作为排序分数、以真实标签 y 作为参照计算得到的 AUC 值；取 s_m 与 $-s_m$ 两个方向中 AUC 较大的一个，用于排除 logit 符号对判别力估计的干扰，以更纯粹地衡量单一模态的独立区分潜力。

各单模态 logit 的 signed AUC 集中于 0.50–0.57 之间，整体偏低，表明无论在哪个变体中，单模态 logit head 均未形成足够强的独立分类器。这与 ACMF 的设计初衷相符：MDS 的目标不是让某一模态单独完成 CTR 预测，而是为其提供稳定的训练信号，使其在联合建模中不至于完全沦为无梯度的”摆设”。从数值上看，attr 在含 MDS 的变体中的 signed AUC 约为 0.565–0.567，明显高于其余三类，与属性模态强判别力的结论一致。ACMF-ELF 的各模态 signed AUC 分布更为均匀且偏低（多数接近 0.51），进一步印证了缺少独立监督时单模态表示质量普遍较弱的判断。点击信号的主要承载仍在于 DIN 用户兴趣、个性化门控与 DNN 的联合表示，单模态 logit head 所扮演的是辅助校正的角色，而非独立预测器。

表 10: 各模态单独 logit 的方向校正 AUC

模型	text	image	attr	item
ACMF-MDS	0.503	0.508	0.566	0.531
ACMF-ELF	0.512	0.516	0.507	0.517
ACMF-MDS-ELF	0.512	0.501	0.567	0.531
ACMF-FULL	0.512	0.503	0.565	0.529



图 8: 各模态单独 logit 的方向校正 AUC。

6 讨论

6.1 MDS 与 ELF 相互依存的机制解释

消融实验表明，单独使用 MDS 或 ELF 均无法取得理想效果，原因在于二者分别对应训练与推理两个阶段，缺一不可。MDS 在训练阶段为每个单模态 logit head 施加独立监督，使 s_m 具备判别意义；ELF 在推理阶段以权重 π 与标量 α 将 s_m 接入主路径 logit。若无 MDS，s_m 未经独立训练、判别性不足，ELF 引入的更多是噪声而非有效信号；若无 ELF，MDS 训练出的判别力仅体现在辅助损失中，不会传递到最终预测 logit 上。因此 MDS 提供判别信号，ELF 提供接入最终预测的通路，二者构成完整链路，这也是组合方案优于任一单一方案的原因。

6.2 接受不均衡而非强制均衡的建模原则

门控分布与模态消融的结果共同表明，属性模态在当前数据集中具有明显的判别优势。若人为强制各模态权重均等（例如固定为每类 0.25），并不能消除这种数据内生的不均衡，反而会限制模型对最有效特征的利用。据此，本文采取的建模原则是保留而非消除这种不均衡：以固定的先验平滑系数 $\lambda = 0.5$ 为弱模态保留最低限度的参与空间，再由 ACMF 使其在训练与推理阶段发挥辅助作用。主门控中属性权重为 0.625，保留了对强模态的依赖；late branch 中文本（0.281）与图像

（0.273）权重高于属性（0.204），说明该分支学到的模态偏好与主路径不同，更多依赖内容模态提供补充信息。两条路径的分工使模型能够同时改善 AUC 与 Logloss。

6.3 AUC 与 Logloss 走势分离的含义

实验中多次出现 AUC 与 Logloss 走势不一致的现象。AUC 只衡量相对排序，对预测概率的绝对值不敏感；Logloss 直接惩罚预测概率与真实标签的偏差，对概率分布形态更为敏感。ACMF-MDS 提升了 AUC，但 Logloss 随之上升；no-image 变体 AUC 略高于完整模型，但 Logloss 更差。两种情形都说明，改变排序结果与改变概率分布并非同一件事。本文选择 ACMF-MDS-ELF 而非 AUC 更高的 ACMF-MDS，原因是 CTR 预测任务要求同时满足排序与概率校准，仅优化其中一项指标不满足这一要求，这一判断标准在全部实验中保持一致。

7 总结

本文围绕多模态点击率预测中的门控坍缩问题，提出并验证了 ACMF-PMG-DIN。模型以 DIN 目标注意力为用户兴趣建模基础，以个性化多模态门控实现样本级模态选择；先验平滑在保留优势模态主导地位的同时，从权重层面为弱模态提供最低限度的参与保障；ACMF 的 MDS 组件进一步在训练阶段为弱模态补充独立梯度，ELF 组件则将受监督的旁路信号以轻量方式引入最终预测。

实验结果相互印证：属性模态的不可替代性通过模态消融和门控分布两类实验从不同维度得到验证；文本与图像的价值体现在 Logloss 的变化中；MDS 与 ELF 的相互依存关系在组件消融的系统对比中得到验证；late branch 学到的内容模态偏好与主路径的属性偏好形成互补，二者共同构成了完整的模态分工。最终模型未依赖集成或外部数据，在验证集上 AUC 达到 0.982644、Logloss 降至 0.154708；提交 Codabench 官方评测后，测试集 AUC 为 0.9853，Task2 排行榜排名第 13，在单模型单任务的约束下实现了排序与校准的协同提升。

后续工作可以从以下方向继续深化：一是探索更精细的模态可靠性自适应估计，使先验平滑的约束强度随样本特性动态调整，而非固定 λ；二是引入更强的序列建模结构（如多头注意力或双塔架构）以提升用户兴趣的表达质量；三是研究上游多模态表征与下游 CTR 任务的端到端对齐，减少固定 embedding 带来的语义损失。

参考文献

[1] Guorui Zhou, Xiaoqiang Zhu, Chenru Song, Ying Fan, Han Zhu, Xiao Ma, Yanghui Yan, Junqi Jin, Han Li, Kun Gai. Deep Interest Network for Click-Through Rate Prediction. In *Proceedings of the 24th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining (KDD'18)*, 2018, 1059–1068.

[2] Jacob Devlin, Ming-Wei Chang, Kenton Lee, Kristina Toutanova. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. In *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics (NAACL-HLT'19)*, 2019, 4171–4186.

[3] Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Askell, Pamela Mishkin, Jack Clark, Gretchen Krueger, Ilya Sutskever. Learning Transferable Visual Models From Natural Language Supervision. In *Proceedings of the 38th International Conference on Machine Learning (ICML'21)*, PMLR, 2021, 8748–8763.

[4] Yongxin Ni, Yu Ge, Xin Xin, Haitao Yu, Yue Feng, Alexandros Karatzoglou, Ioannis Arapakis, Joemon M. Jose. A Content-Driven Micro-Video Recommendation Dataset at Scale. *arXiv preprint arXiv:2309.15379*, 2023.

[5] Junchen Fu, Xin Ge, Xin Xin, Haitao Yu, Yue Feng, Alexandros Karatzoglou, Ioannis Arapakis, Joemon M. Jose. The 1st EReL@MIR Workshop on Efficient Representation Learning for Multimodal Information Retrieval. *arXiv preprint arXiv:2504.14788*, 2025.

[6] Jiaqi Ma, Zhe Zhao, Xinyang Yi, Jilin Chen, Lichan Hong, Ed H. Chi. Modeling Task Relationships in Multi-task Learning with Multi-gate Mixture-of-Experts. In *Proceedings of the 24th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining (KDD'18)*, 2018, 1930–1939.

[7] Chen-Yu Lee, Saining Xie, Patrick Gallagher, Zhengyou Zhang, Zhuowen Tu. Deeply-Supervised Nets. In *Proceedings of the 18th International Conference on Artificial Intelligence and Statistics (AISTATS'15)*, PMLR, 2015, 562–570.

[8] Tadas Baltrušaitis, Chaitanya Ahuja, Louis-Philippe Morency. Multimodal Machine Learning: A Survey and Taxonomy. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 41(2):423–443, 2019.